Guía de Referencia Modelos Predictivos

1. Conceptos Básicos

Variable aleatoria: función que asigna valores numéricos a sucesos
PDF: función de densidad de probabilidad
CDF: función de distribución acumulada $F(x) = P(X \leq x)$
ECDF: función de distribución empírica

Teorema Fundamental de la Estadística: La distribución empírica converge a la distribución real cuando $n \to \infty$

2. Distribuciones

Distribución	Media	Varianza	Notas
$\text{Bernoulli}(p)$	p	$p(1-p)$	Un ensayo
$\text{Binomial}(n, p)$	np	$np(1-p)$	Suma de n Bernoullis
$\text{Poisson}(\lambda)$	λ	λ	Límite binomial: $n \to \infty, p \to 0, np \to \lambda$
$\text{Normal}(\mu, \sigma)$	μ	σ^2	Estandarizar: $Z = \frac{X-\mu}{\sigma}$
$t(\text{df})$	0	> 1	Colas pesadas; $\to N(0,1)$ cuando df > 30

Cuantil q_p: valor tal que $P(X < q_p) = p$

3. Estadística Inferencial

Estadísticos: media $\bar{x}$, varianza s^2, desviación típica s, cuantiles, percentiles

Estadísticos de la media muestral: si $X_1, \ldots, X_n$ son i.i.d. con media μ y varianza σ^2, entonces $E[\bar{X}] = \mu, \text{Var}(\bar{X}) = \frac{\sigma^2}{n}$

Teorema del Límite Central (TLC): Para n grande, $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ sin importar la distribución original

Intervalo de confianza de $100(1-\alpha)$**%**: $\bar{x} \pm z_{\alpha/2}\frac{s}{\sqrt{n}}$

$z_{\alpha/2}$ es el cuantil de la distribución normal estándar tal que $P(Z > z_{\alpha/2}) = \frac{\alpha}{2}$

4. Contraste de Hipótesis

- **Hipótesis nula** H_0: suposición a contrastar
- **Hipótesis alternativa** H_1: lo que se acepta si se rechaza H_0
- **Nivel de significación** α: probabilidad de error tipo I (típico: 0.05)
- **Test unilateral**: $H_1 : \mu > \mu_0$ o $\mu < \mu_0$
- **Test bilateral**: $H_1 : \mu \neq \mu_0$

Test	Uso	Estadístico
z-test	Media con σ conocida o TLC	$z = \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}}$
t-test	Media con σ desconocida	$t = \frac{\bar{x}-\mu_0}{s/\sqrt{n}}$
t-test pareado	Diferencias entre observaciones emparejadas	$t = \frac{\bar{d}}{s_d/\sqrt{n}}$

- Debido a TLC, podemos aproximar la distribucion de la media muestral de Bernoulli(p) o p de Binomial(n,p) con Normal(p, $p(1-p)/n$) cuando n grande (e.g. $n > 30$) y p suficientemente próxima a 0.5 (e.g. tal que $np > 5$).

Región de rechazo: valores del estadístico que llevan a rechazar H_0

p-valor: probabilidad de obtener un estadístico igual o más extremo que el observado bajo H_0. Rechazar hipótesis nula si p-valor $< \alpha$, no rechazar en caso contrario.

5. Regresión Lineal

Modelo: $y = \beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n + \epsilon$

Covarianza: $\mathrm{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$
Correlación: $\rho = \frac{\mathrm{Cov}(X,Y)}{\sigma_X \sigma_Y}$ (entre -1 y 1)

Interpretación coeficientes: β_j = cambio en y por unidad de X_j (manteniendo resto constante)

Coeficiente significativo: p-valor $< \alpha$ (típicamente 0.05)

Bondad de Ajuste

- R^2: proporción varianza explicada (0 a 1)
- R^2 **ajustado**: penaliza complejidad
- **AIC/BIC**: cuanto más pequeños, mejor

Requisitos

- Linealidad
- Independencia de errores
- Homocedasticidad (varianza constante)
- Normalidad de residuos
- No multicolinealidad

Multicolinealidad: correlación alta entre predictores → coeficientes inestables. Evitar: eliminar variables correlacionadas o VIF > 10

Diagnóstico residuos: verificar media 0, varianza constante, independencia

6. Regresión Logística

Función sigmoide: $\sigma(z) = \frac{1}{1+e^{-z}}$ donde $z = \beta_0 + \beta_1 X_1 + \cdots$

Predicción: probabilidad entre 0 y 1; aplicar threshold (típico: 0.5)

Matriz de Confusión

	Predicho Positivo	**Predicho Negativo**
Real Positivo	VP (True Positive)	FN (False Negative)
Real Negativo	FP (False Positive)	VN (True Negative)

Métricas

- **Accuracy**: $\frac{VP+VN}{VP+VN+FP+FN}$
- **Precision**: $\frac{VP}{VP+FP}$
- **Recall/Sensitivity**: $\frac{VP}{VP+FN}$
- **F1 Score**: $\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision}+\text{Recall}}$
- **TPR**: True Positive Rate = Recall
- **FPR**: False Positive Rate = $\frac{FP}{FP+VN}$

Curva ROC: TPR vs FPR; **AUC**: área bajo curva (mejor cuanto más cerca de 1)

7. Feature Engineering

Codificación variables categóricas:

- One-hot encoding
- Label encoding (ordinales)

Transformaciones no lineales:

- Potencias: $X^2, X^3, \sqrt{X}$
- Logaritmos: $\log(X)$
- Trigonométricas: $\sin(X), \cos(X)$
- Segmentación: discretizar continuas

Interacciones: productos $X_1 \cdot X_2$ u otras combinaciones no lineales de dos o más variables

8. Árboles de Decisión

Entrenamiento: seleccionar (variable, punto corte) que maximiza pureza en cada nodo; repetir hasta criterios de parada

Criterios de pureza:

- Clasificación: Gini, entropía
- Regresión: MSE (error cuadrático medio), MAE (error absoluto medio)

Hiperparámetros (valores típicos)

- `max_depth` : 3-10
- `min_samples_split` : 2-10
- `min_samples_leaf` : 2-10
- `max_features` : auto, sqrt, log2
- `criterion` : gini, mse, entropy

Overfitting: modelo demasiado complejo, mal en test
Underfitting: modelo demasiado simple, mal en train y test

Importancia de variables: contribución de cada variable al desempeño

Ensambles

- **Random Forest**: múltiples árboles construidos paralelamente muestreando observaciones y variables
  - Hiperparámetros: `n_estimators` , + los de árbol
- **Gradient Boosting**: árboles secuenciales corrigiendo errores de los anteriores
  - Hiperparámetros: `n_estimators` , `learning_rate` , + los de árbol

Trade-off: flexibilidad vs interpretabilidad

9. Validación y Optimización

Train-test split: dividir datos (típico: 70-30 o 80-20)
Cross-validation: k-fold para validación robusta

Optimización hiperparámetros:

- Grid Search: exhaustivo
- Random Search: aleatorio
- Guided Search: tiene en cuenta búsquedas previas (Optuna)

10. Clasificación Multiclase

- **One-vs-Rest (OvR)**: un clasificador por clase vs resto → más rápido
- **One-vs-One (OvO)**: un clasificador por par de clases → más preciso con clases desequilibradas

11. Series Temporales

El orden de las observaciones importa y hay que tenerlo en cuenta al definir el modelo, al entrenar, al evaluar y al predecir

Descomposición aditiva: $Y_t = \text{Tendencia} + \text{Estacionalidad} + \text{Ruido}$