MODELOS PREDICTIVOS EN EL ANÁLISIS DE NEGOCIOS

Regresión Lineal Múltiple

Limitaciones de la regresión simple

En el mundo real:

- Los fenómenos dependen de **múltiples factores**
- Una sola variable raramente explica todo
- Necesitamos modelos más complejos

Regresión simple:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Preguntas de negocio:

- ¿Cómo afectan superficie, ubicación y antigüedad al precio de una vivienda?
- ¿Las ventas dependen de publicidad online, TV y radio simultáneamente?
- ¿El salario se explica por experiencia, educación y sector?

Regresión lineal múltiple

Definición:

- Extensión de la regresión simple
- **Múltiples variables independientes**
- Relación lineal entre Y y cada X_i
- Permite controlar varios factores simultáneamente

Ecuación general:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \varepsilon$$

Predicción:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \ldots + \hat{\beta}_p X_p$$

Regresión lineal múltiple

Ventajas:

- Modelos más realistas
- Mayor poder explicativo y predictivo
- Control de factores de confusión

Ejemplo con 2 variables:

$$Y = \text{Precio Vivienda}$$

$$X_1 = \text{Superficie } (m^2)$$

$$X_2 = \text{Antigüedad } (años)$$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Componentes del modelo múltiple

Ecuación:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \varepsilon$$

- Y: variable dependiente (respuesta)
- $X_1, X_2, \ldots, X_p$: variables independientes (predictores)
- β_0: **intercepto**
- $\beta_1, \beta_2, \ldots, \beta_p$: **coeficientes parciales**
- ε: error aleatorio

Componentes del modelo múltiple

Ecuación:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_p X_p + \varepsilon$$

Ecuación matricial:

$$Y = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

- Y: variable dependiente (respuesta)
- $\boldsymbol{X}$: variables independientes, incluyendo columna de unos para el intercepto
- $\boldsymbol{\beta}$: vector de coeficientes
- $\boldsymbol{\varepsilon}$: vector de errores aleatorios

Componentes del modelo múltiple

Interpretación de β_j:

Efecto parcial de X_j sobre Y, **manteniendo constantes** las demás variables

Ejemplo:

- Si en el modelo de precio de vivienda $\beta_1 = 2000$
  - Entonces cada m²adicional aumenta el precio en 2000€, **para viviendas de la misma antigüedad**

Supuestos del modelo múltiple

Los del modelo simple, más uno nuevo:

Ausencia de multicolinealidad

- La multicolinealidad es la correlación alta o dependencia lineal entre variables predictoras.
- Es decir hay multicolinealidad, si pueden predecirse las variables independientes entre sí:

$$X_4 \approx \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \alpha_3 X_3$$

Ejemplo:

En un modelo de salarios:

- X_1: Años de experiencia
- X_2: Edad del empleado

Si todos empezaron a trabajar en torno a los 23 años:

$$X_2 \approx 23 + X_1$$

Multicolinealidad

Consecuencias

- Errores estándar inflados
    - Coeficientes **menos precisos**
    - **Significación reducida**
- Modelo inestable
    - **Pequeñas variaciones** en datos producen **grandes cambios** en coeficientes
    - Repeticiones del experimento producen **modelos diferentes**
    - Coeficientes con **signos inesperados**
    - **Dificultad para interpretar** efectos individuales

Multicolinealidad

Detección:

1. **Correlación alta entre variables**: $|r_{ij}| > 0.8$ es preocupante
2. **VIF (Variance Inflation Factor)**:

$$VIF_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión de X_j sobre las demás X

- $VIF < 5$: sin problemas
- $VIF > 10$: multicolinealidad severa

Soluciones:

- Eliminar variables redundantes
- Combinar variables correlacionadas
- Usar técnicas de regularización

Ejemplo práctico: Precio de viviendas

Apliquemos estos conceptos a un caso real donde veremos cómo detectar y resolver la multicolinealidad.

Una inmobiliaria quiere predecir el precio de viviendas usando tres variables:

Variables:

- Y: Precio (miles €)
- X_1: Superficie (m²)
- X_2: Antigüedad (años)
- X_3: Distancia al centro (km)

Datos (15 viviendas):

Precio	m²	Años	Km
211	75	19	2.0
250	90	17	3.0
293	100	22	1.5
…	…	…	…

Ejemplo: Precio de viviendas

Modelo estimado:

$$\hat{Y} = -16.3 + 2.67X_1 + 2.02X_2 - 5.01X_3$$

Interpretación:

Coeficiente	valor	unidad	Interpretación
β_0	-16.3	k€	Precio base sin considerar variables
β_1	2.67	k€/m²	Cada m² adicional aumenta el precio en 2,670€
β_2	2.02	k€/año	Cada año de antigüedad aumenta el precio en 2,020€
β_3	-5.01	k€/km	Cada km al centro reduce el precio en 5,010€

Ejemplo: Python con statsmodels

```python
import pandas as pd
import statsmodels.api as sm

# Datos
data = {
    'superficie': [75, 90, 100, 85, 95, 70, 110, 80, 88, 92, 78, 105, 82, 96, 89],
    'antiguedad': [19, 17, 22, 17, 8, 5, 22, 12, 15, 19, 5, 21, 11, 15, 12],
    'distancia': [2.0, 3.0, 1.5, 2.5, 5.0, 6.0, 1.0, 4.0, 3.5, 2.2, 5.5, 1.8, 4.5, 3.2, 3.8],
    'precio': [211, 250, 293, 238, 229, 157, 320, 197, 234, 247, 176, 295, 194, 251, 223]
}
df = pd.DataFrame(data)

# Preparar variables
X = df[['superficie', 'antiguedad', 'distancia']]
y = df['precio']
X = sm.add_constant(X)  # Añadir intercepto

# Ajustar modelo
modelo = sm.OLS(y, X).fit()

# Resultados completos
print(modelo.summary())

# Predicción
nueva_vivienda = pd.DataFrame({
    'const': [1],
    'superficie': [85],
    'antiguedad': [7],
    'distancia': [2.5]
})
prediccion = modelo.predict(nueva_vivienda)
print(f"\nPrecio predicho: {prediccion.values[0]:.2f} miles €")
```

Análisis del output de statsmodels OLS

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.987
Model:                            OLS   Adj. R-squared:                  0.983
Method:                 Least Squares   F-statistic:                     270.3
Date:                Thu, 13 Nov 2025   Prob (F-statistic):           1.39e-10
Time:                        13:43:12   Log-Likelihood:                -45.491
No. Observations:                  15   AIC:                             99.0
Df Residuals:                      11   BIC:                             101.8
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        -16.3259     54.995     -0.297      0.772    -137.368     104.717
superficie     2.6692      0.188     14.228      0.000       2.256       3.082
antiguedad     2.0208      1.897      1.065      0.310      -2.155       6.197
distancia     -5.0115      7.248     -0.691      0.504     -20.965      10.942
==============================================================================
Omnibus:                        0.989   Durbin-Watson:                   1.573
Prob(Omnibus):                  0.610   Jarque-Bera (JB):                0.835
Skew:                          -0.337   Prob(JB):                        0.659
Kurtosis:                       2.061   Cond. No.                     3.33e+03
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 3.33e+03. This might indicate that there are
strong multicollinearity or other numerical problems.
```

Selección de variables

Cuando tenemos muchas variables, es importante decidir cuáles mantener en el modelo.

- No todas las variables son relevantes
- Modelos simples son preferibles
- Modelos interpretables son preferibles

Criterios:

1. **Significancia estadística** (p-valores)
2. **Conocimiento del sector**
3. R^2 **ajustado**
4. **AIC/BIC** (criterios de información)

Selección: 1. Significancia estadística (p-valores)

Si el coeficiente $\beta_j \neq 0$ significativamente, entonces X_j tiene efecto sobre Y.

Hipótesis para cada β_j:

$$H_0 : \beta_j = 0 \text{ (no hay efecto)}$$

$$H_1 : \beta_j \neq 0 \text{ (hay efecto)}$$

Estadístico t:

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$$

Bajo H_0: $t \sim t_{n-p-1}$

Interpretación del p-valor ($\alpha = 0.05$):

- $p < 0.05$: rechazamos H_0
  - La variable X_j es significativa
  - Tiene efecto sobre Y
- $p \geq 0.05$: no rechazamos H_0
  - No hay evidencia de efecto
  - Considerar eliminar la variable

Intervalo de confianza:

$$\hat{\beta}_j \pm t_{\alpha/2,n-p-1} \times SE(\hat{\beta}_j)$$

Selección: 1. Significancia estadística - Ejemplo

```
                coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        -16.3259     54.995     -0.297      0.772    -137.368     104.717
superficie     2.6692      0.188     14.228      0.000       2.256       3.082
antiguedad     2.0208      1.897      1.065      0.310      -2.155       6.197
distancia     -5.0115      7.248     -0.691      0.504     -20.965      10.942
```

Variable	coef	std err	t	P>|t|	Decisión
superficie	2.67	0.188	14.228	**0.000**	Mantener
antigüedad	2.02	1.897	1.065	0.310	Eliminar
distancia	-5.01	7.248	-0.691	0.504	Eliminar

Conclusión: Solo `superficie` es significativa ($p < 0.05$). Según este criterio, debemos eliminar las otras dos

Selección: 1. Modelo reducido (solo superficie)

Siguiendo el criterio de p-valores, probamos un modelo solo con `superficie`:

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.885
Model:                            OLS   Adj. R-squared:                  0.877
Method:                 Least Squares   F-statistic:                     100.5
Date:                Thu, 13 Nov 2025   Prob (F-statistic):           1.75e-07
No. Observations:                  15   AIC:                             127.2
Df Residuals:                      13   BIC:                             128.6
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       -103.3853     33.938     -3.046      0.009    -176.704     -30.067
superficie     3.7946      0.379     10.024      0.000       2.977       4.612
==============================================================================
```

Problema: R^2_{adj} baja de 0.983 a 0.877. ¿Hemos perdido información importante?

Selección: 2. Conocimiento del sector

El criterio estadístico sugiere eliminar ambas variables, pero el conocimiento del negocio nos dice algo diferente.

Observación clave:

Las casas más **antiguas** suelen estar **más cerca del centro** (los centros urbanos se desarrollaron primero).

En nuestros datos:

- Alta correlación antigüedad-distancia
- Esto explica por qué `antigüedad` tenía coeficiente positivo: capturaba el efecto de la ubicación céntrica

Análisis:

- Ni `antigüedad` ni `distancia` son significativas en el modelo completo
- Pero ambas explican lo mismo: **ubicación céntrica**
- Sus efectos se "cancelan" mutuamente (multicolinealidad)

Selección: 2. Modelo propuesto (superficie + distancia)

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.985
Model:                            OLS   Adj. R-squared:                  0.983
No. Observations:                  15   AIC:                             98.5
Df Residuals:                      12   BIC:                             100.6
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const         38.1993     20.197      1.891      0.083      -5.806      82.205
superficie     2.6705      0.189     14.157      0.000       2.259       3.082
distancia    -12.5881      1.398     -9.007      0.000     -15.633      -9.543
==============================================================================
```

¡Ahora `distancia` es significativa! ($p < 0.001$)

Al eliminar `antigüedad`, se resuelve la multicolinealidad y `distancia` muestra su efecto.

Selección: 3. R^2 ajustado

R^2 (recordatorio)

Queremos incluir variables que mejoren el ajuste del modelo, que podemos medir con R^2.

Coeficiente de determinación R^2:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

- Proporción de variabilidad explicada
- $0 \leq R^2 \leq 1$

Problema R^2 siempre aumenta al añadir variables, incluso si son irrelevantes

Solución: usar R^2 ajustado

Selección: 3. R^2 ajustado

R^2 ajustado:

$$R^2_{adj} = 1 - \frac{\frac{SS_{res}}{n-p-1}}{\frac{SS_{tot}}{n-1}}$$

donde p es el número de predictores

- R^2_{adj} penaliza la inclusión de variables innecesarias
- Si R^2_{adj} no aumenta al añadir una variable, esa variable no mejora el modelo
- Permite comparar modelos con diferentes números de predictores
- $R^2_{adj} < R^2$ siempre
  - Si la diferencia es muy grande, hay muchas variables poco útiles

Selección: 3. R^2 ajustado - Validación

Comparación de modelos:

Modelo	Variables	R^2	R^2_{adj}
Completo	superficie, antigüedad, distancia	0.987	0.983
Solo superficie	superficie	0.885	0.877
Propuesto	**superficie, distancia**	**0.985**	**0.983**

Observaciones:

- Modelo propuesto: $R^2_{adj} = 0.983$
- Modelo completo: $R^2_{adj} = 0.983$

Conclusión:

- **Mismo ajuste** con una variable menos
- Eliminar `antigüedad` **mantiene** el R^2_{adj}

.

Selección: 4. AIC/BIC (Criterios de información)

AIC (Akaike Information Criterion):

$$AIC = 2k - 2\ln(L)$$

BIC (Bayesian Information Criterion):

$$BIC = k\ln(n) - 2\ln(L)$$

donde:

- k: número de parámetros
- n: número de observaciones
- L: verosimilitud del modelo

Características:

- **Menor es mejor**
- Penalizan complejidad del modelo
- BIC penaliza más que AIC

Uso:

- Comparar modelos alternativos
- Elegir el modelo con menor AIC/BIC

Selección: 4. AIC/BIC - Validación

Comparación de modelos:

Modelo	Variables	AIC	BIC	R^2_{adj}
Completo	superficie, antigüedad, distancia	99.0	101.8	0.983
Solo superficie	superficie	127.2	128.6	0.877
Propuesto	**superficie, distancia**	**98.5**	**100.6**	**0.983**

Conclusión:

- El modelo propuesto tiene el **menor AIC y BIC**
- Valida nuestra decisión: `superficie + distancia` es el mejor modelo

Selección: Modelo final

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.985
Model:                            OLS   Adj. R-squared:                  0.983
No. Observations:                  15   AIC:                             98.5
Df Residuals:                      12   BIC:                             100.6
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const         38.1993     20.197      1.891      0.083      -5.806      82.205
superficie     2.6705      0.189     14.157      0.000       2.259       3.082
distancia    -12.5881      1.398     -9.007      0.000     -15.633      -9.543
==============================================================================
```

$$\hat{Y} = 38.2 + 2.67 \cdot \text{superficie} - 12.59 \cdot \text{distancia}$$

Ambas variables ahora significativas ($p < 0.001$). La multicolinealidad se resolvió.

Métricas de bondad de ajuste: Resumen

Antes de pasar al diagnóstico, resumimos las métricas usadas para seleccionar el mejor modelo:

Métrica	Qué mide	Valores
R^2	Varianza explicada	Mayor es mejor
R^2 ajustado	Varianza explicada ajustada por número de variables	Mayor es mejor
AIC	Calidad del modelo ajustada por el número de parámetros	Menor es mejor
BIC	Calidad del modelo ajustada por el número de parámetros	Menor es mejor

Diagnóstico del modelo

Ya seleccionamos el mejor modelo (`superficie + distancia`). Ahora debemos verificar que cumple los supuestos de la regresión.

Objetivo:

Verificar que los supuestos del modelo se cumplen para asegurar validez de inferencias y predicciones.

Métodos:

1. **Métricas de diagnóstico** (output de statsmodels)
2. **Gráficos de residuos**

Métricas de diagnóstico (Output de statsmodels):

Métrica	Qué mide	Valores aceptables ($\alpha = 0.05$)
Omnibus	Normalidad de residuos (asimetría + curtosis)	p-valor > 0.05
Prob(Omnibus)	p-valor del test Omnibus	> 0.05
Skew	Asimetría de residuos	Cercano a 0
Kurtosis	Curtosis de residuos	Cercano a 3
Durbin-Watson	Autocorrelación de residuos	1.5 - 2.5
Prob(JB)	p-valor del test Jarque-Bera	> 0.05
Cond. No.	Multicolinealidad	> 1000: posible problema (o falso positivo por valores altos)

Diagnóstico del modelo propuesto (superficie + distancia)

```
==============================================================================
Omnibus:                        0.843   Durbin-Watson:                   1.633
Prob(Omnibus):                  0.656   Jarque-Bera (JB):                0.689
Skew:                           0.158   Prob(JB):                        0.708
Kurtosis:                       1.999   Cond. No.                     1.19e+03
==============================================================================
```

Valores fuera de rango ideal:

Métrica	Valor	Interpretación
Kurtosis	1.999	< 3: colas menos pesadas que normal
Cond. No.	1190	> 1000: posible multicolinealidad residual

Nota: El Cond. No. alto se debe a la escala de las variables, no a multicolinealidad real.

Diagnóstico visual

Las métricas numéricas son útiles, pero los gráficos permiten detectar patrones adicionales.

Gráficos de residuos (del modelo propuesto):

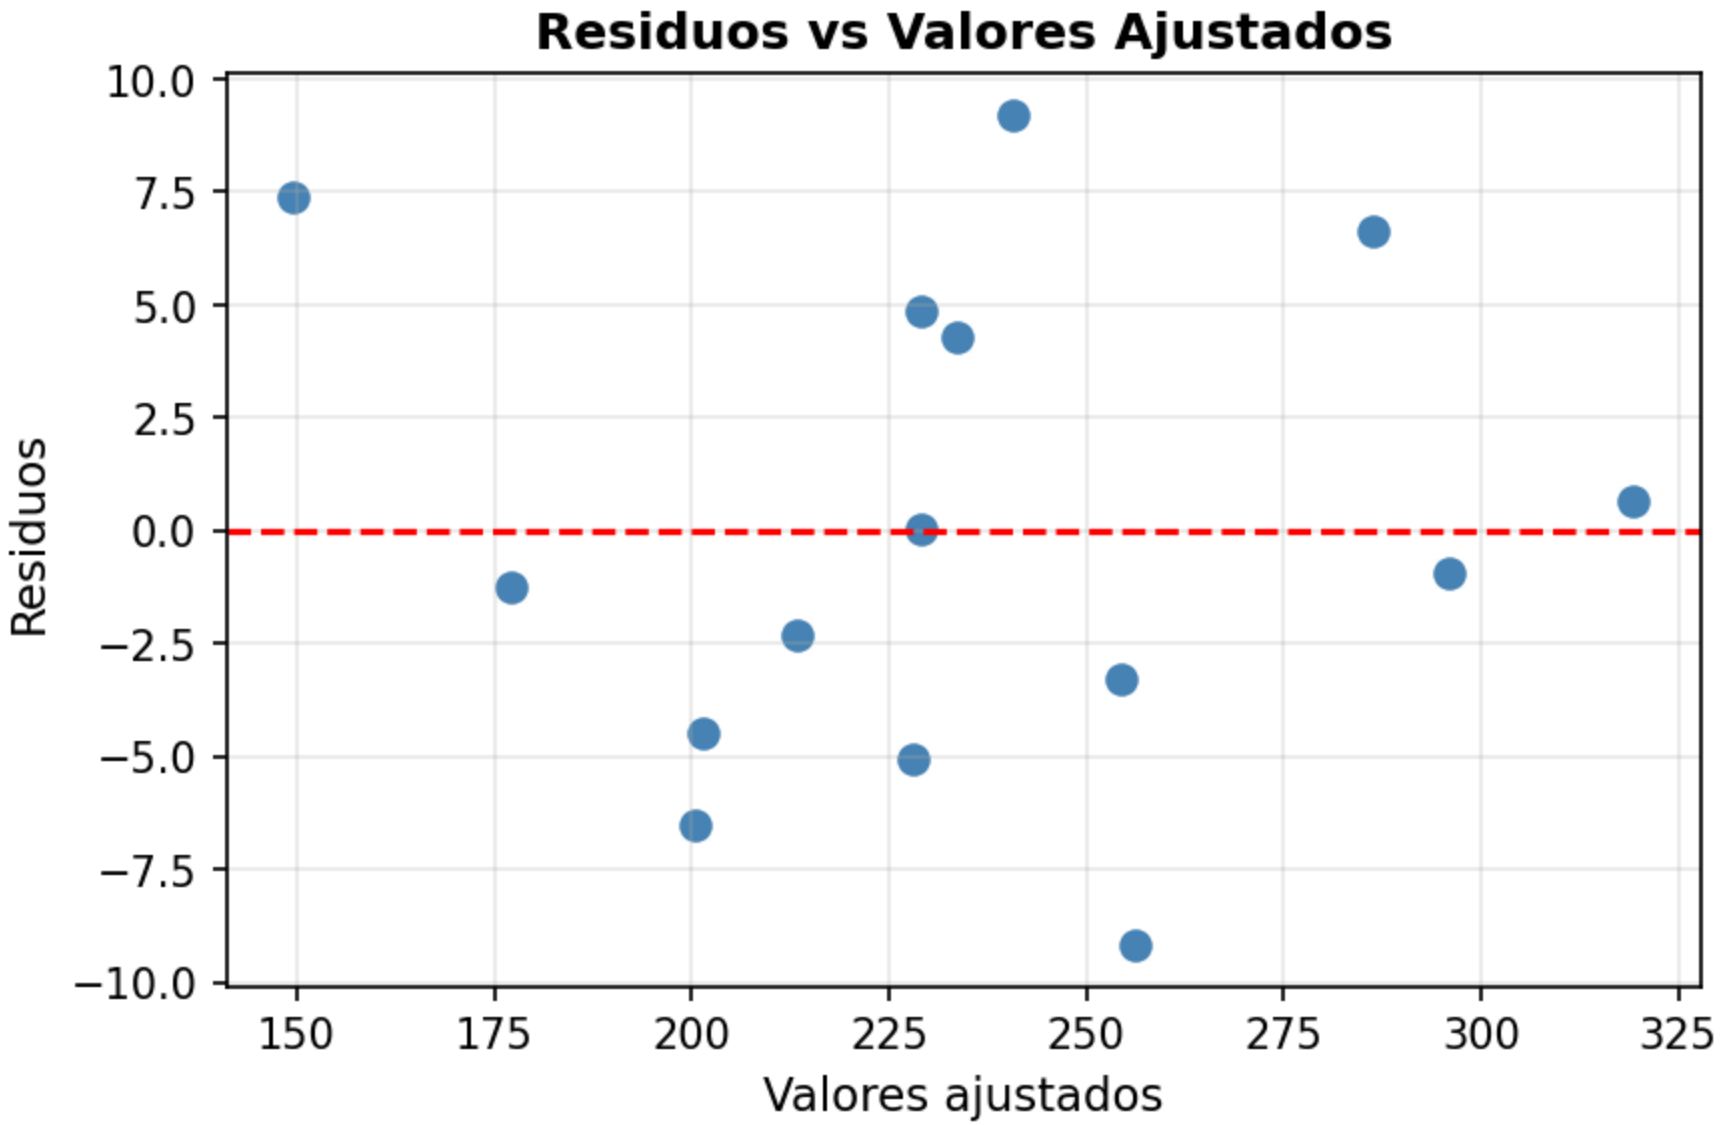
1. **Residuos vs valores ajustados** → Linealidad y homocedasticidad
2. **Q-Q plot** → Normalidad
3. **Scale-Location** → Homocedasticidad
4. **Residuos vs orden** → Independencia (autocorrelación)

Diagnóstico: Residuos vs Valores Ajustados

- Deben estar aleatoriamente distribuidos alrededor de 0
- Sin patrones evidentes y con varianza constante

```
residuos = modelo.resid
valores_ajustados = modelo.fittedvalues

plt.scatter(valores_ajustados, residuos)
plt.axhline(y=0, color='r', linestyle='--')
```

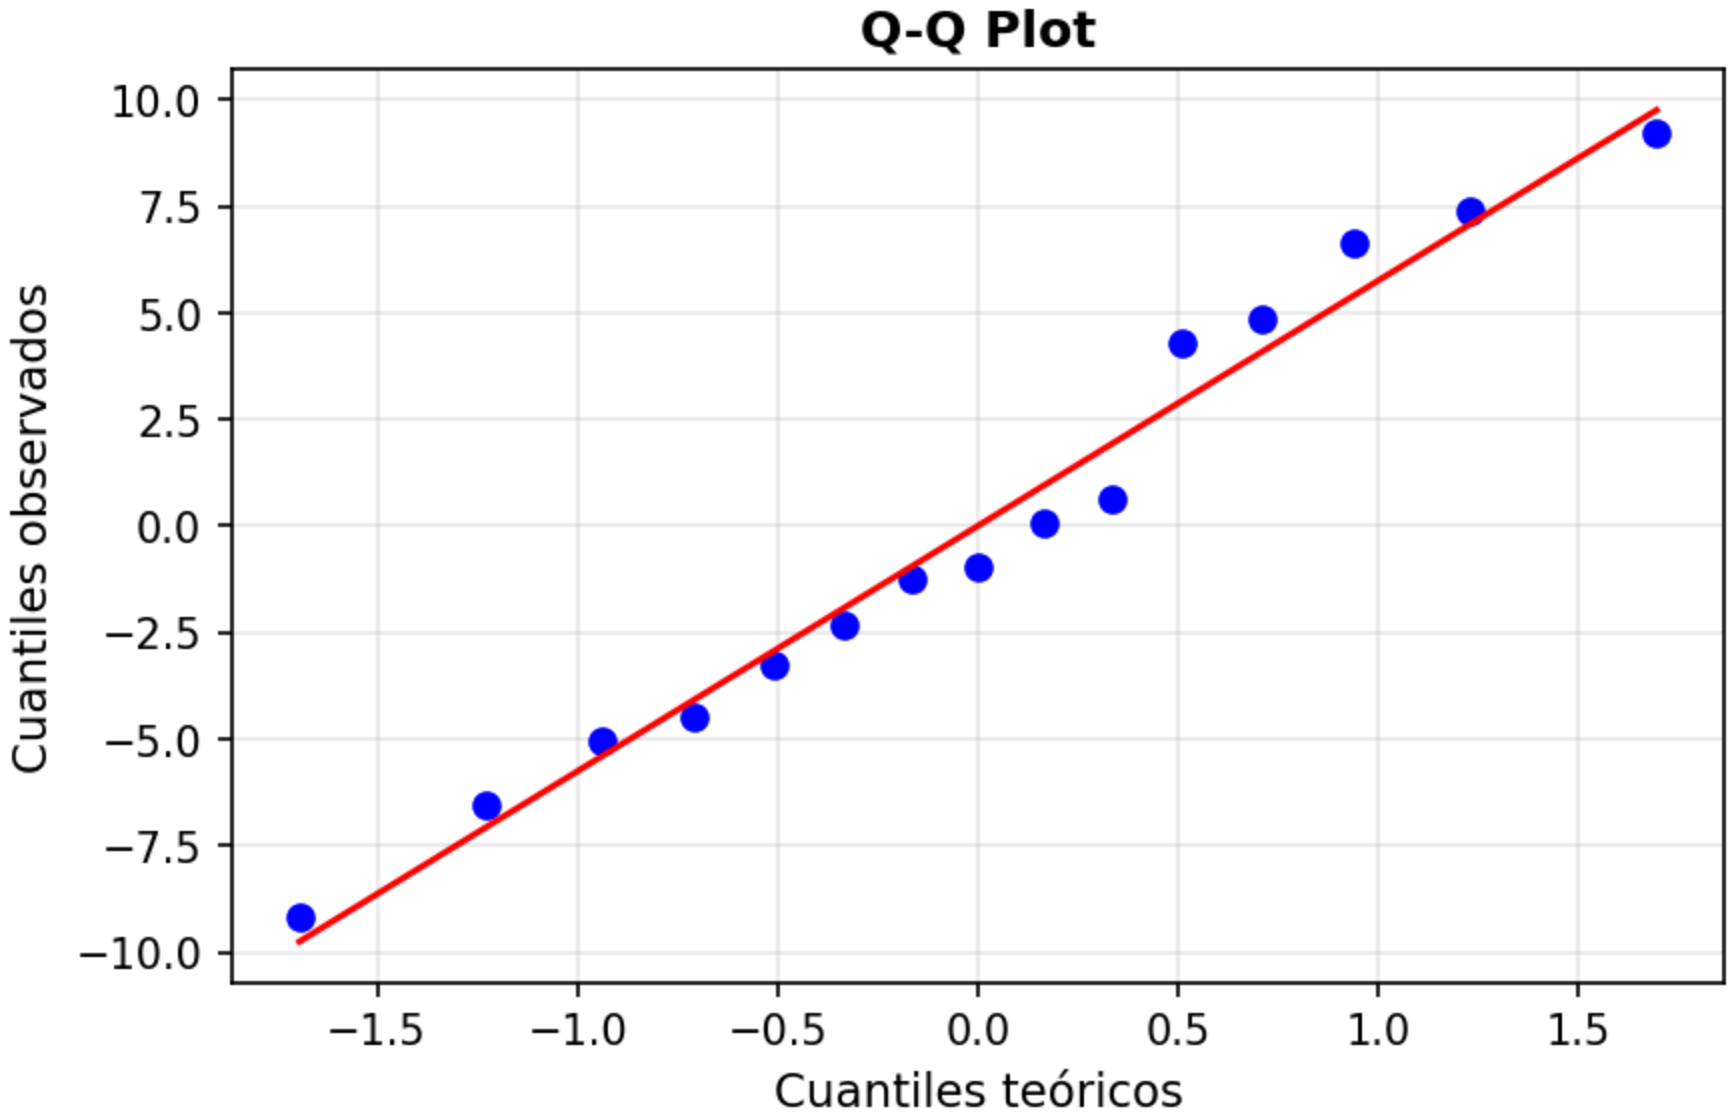

Residuos vs Valores Ajustados
Residuos
Valores ajustados
10.0
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
150
175
200
225
250
275
300
325

Diagnóstico: Q-Q Plot

- Los residuos deben seguir una distribución normal
- Si son normales, deben alinearse cerca de la línea diagonal

```
from scipy import stats as sp_stats

residuos = modelo.resid
sp_stats.probplot(residuos, dist="norm", plot=plt)
```

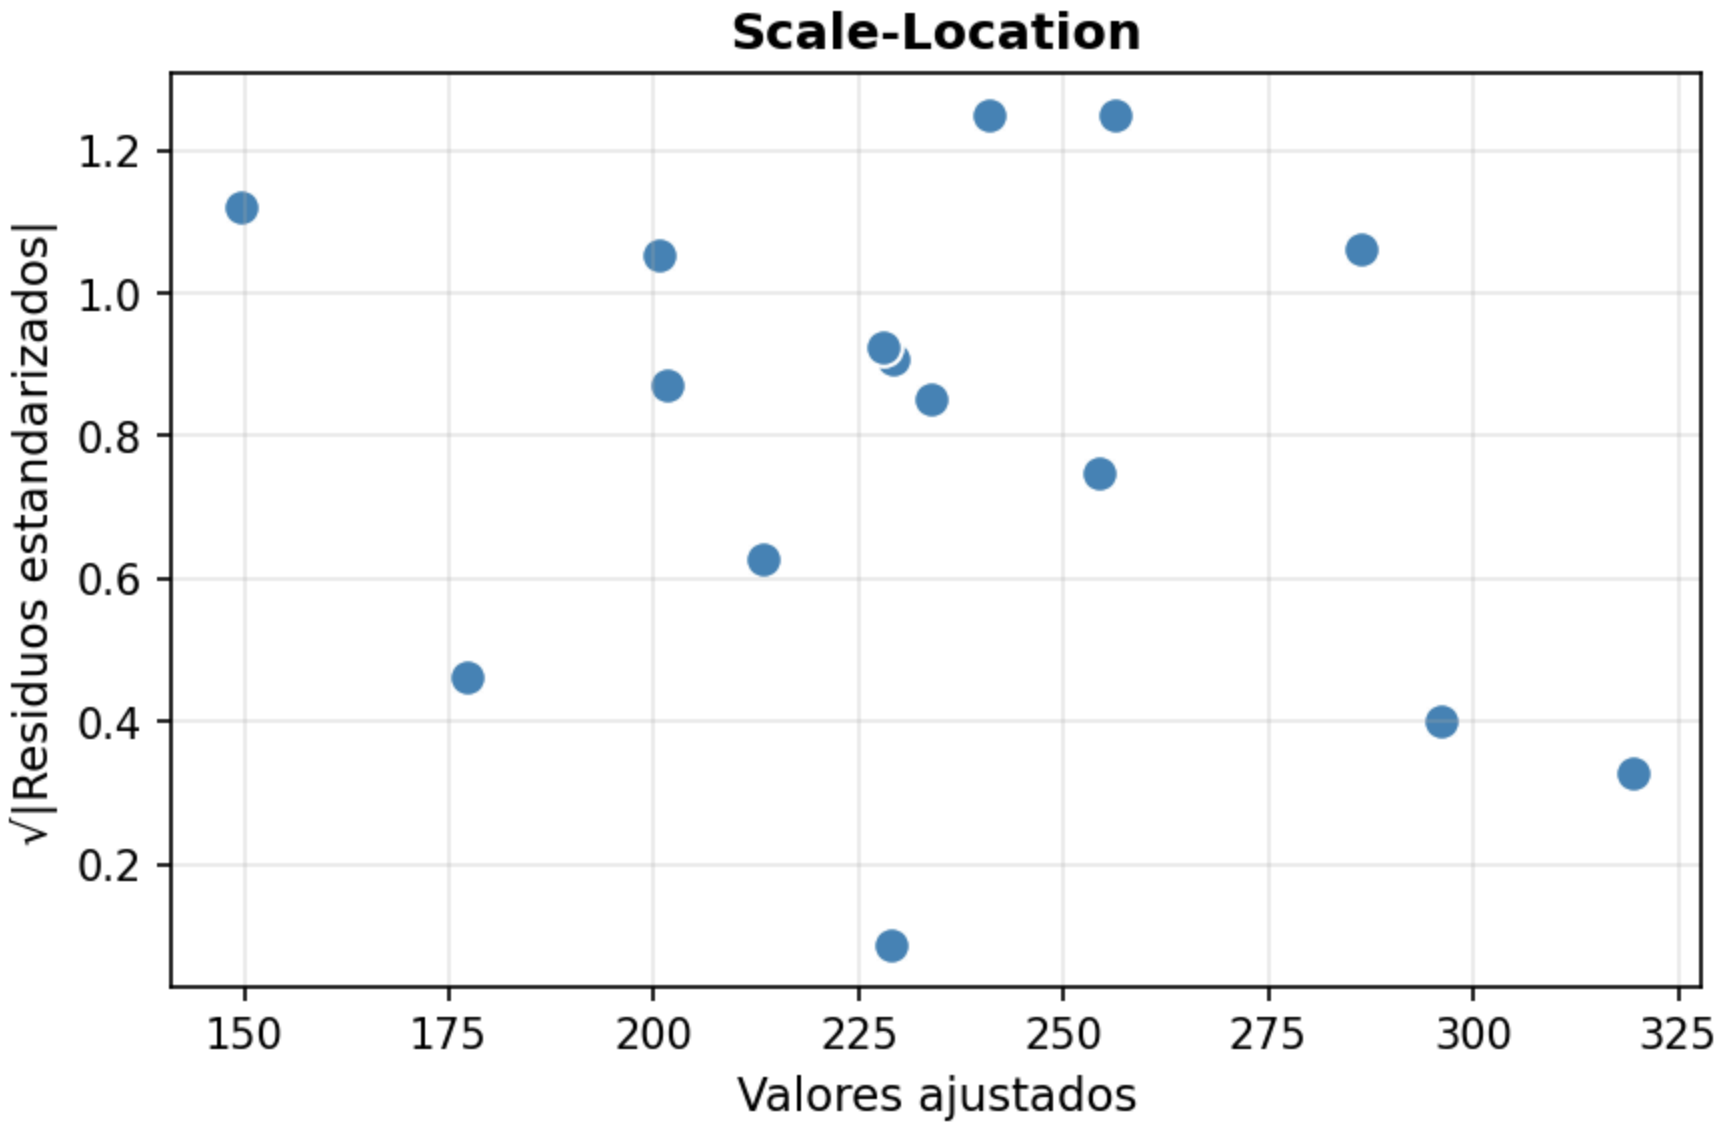

Q-Q Plot
Cuantiles observados
Cuantiles teóricos
10.0
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5

Diagnóstico: Scale-Location

- Detecta heterocedasticidad (varianza no constante)
- Debe mostrar dispersión uniforme

```
residuos_estandarizados = modelo.resid_pearson
valores_ajustados = modelo.fittedvalues

plt.scatter(valores_ajustados, np.sqrt(np.abs(residuos_estandarizados)))
```

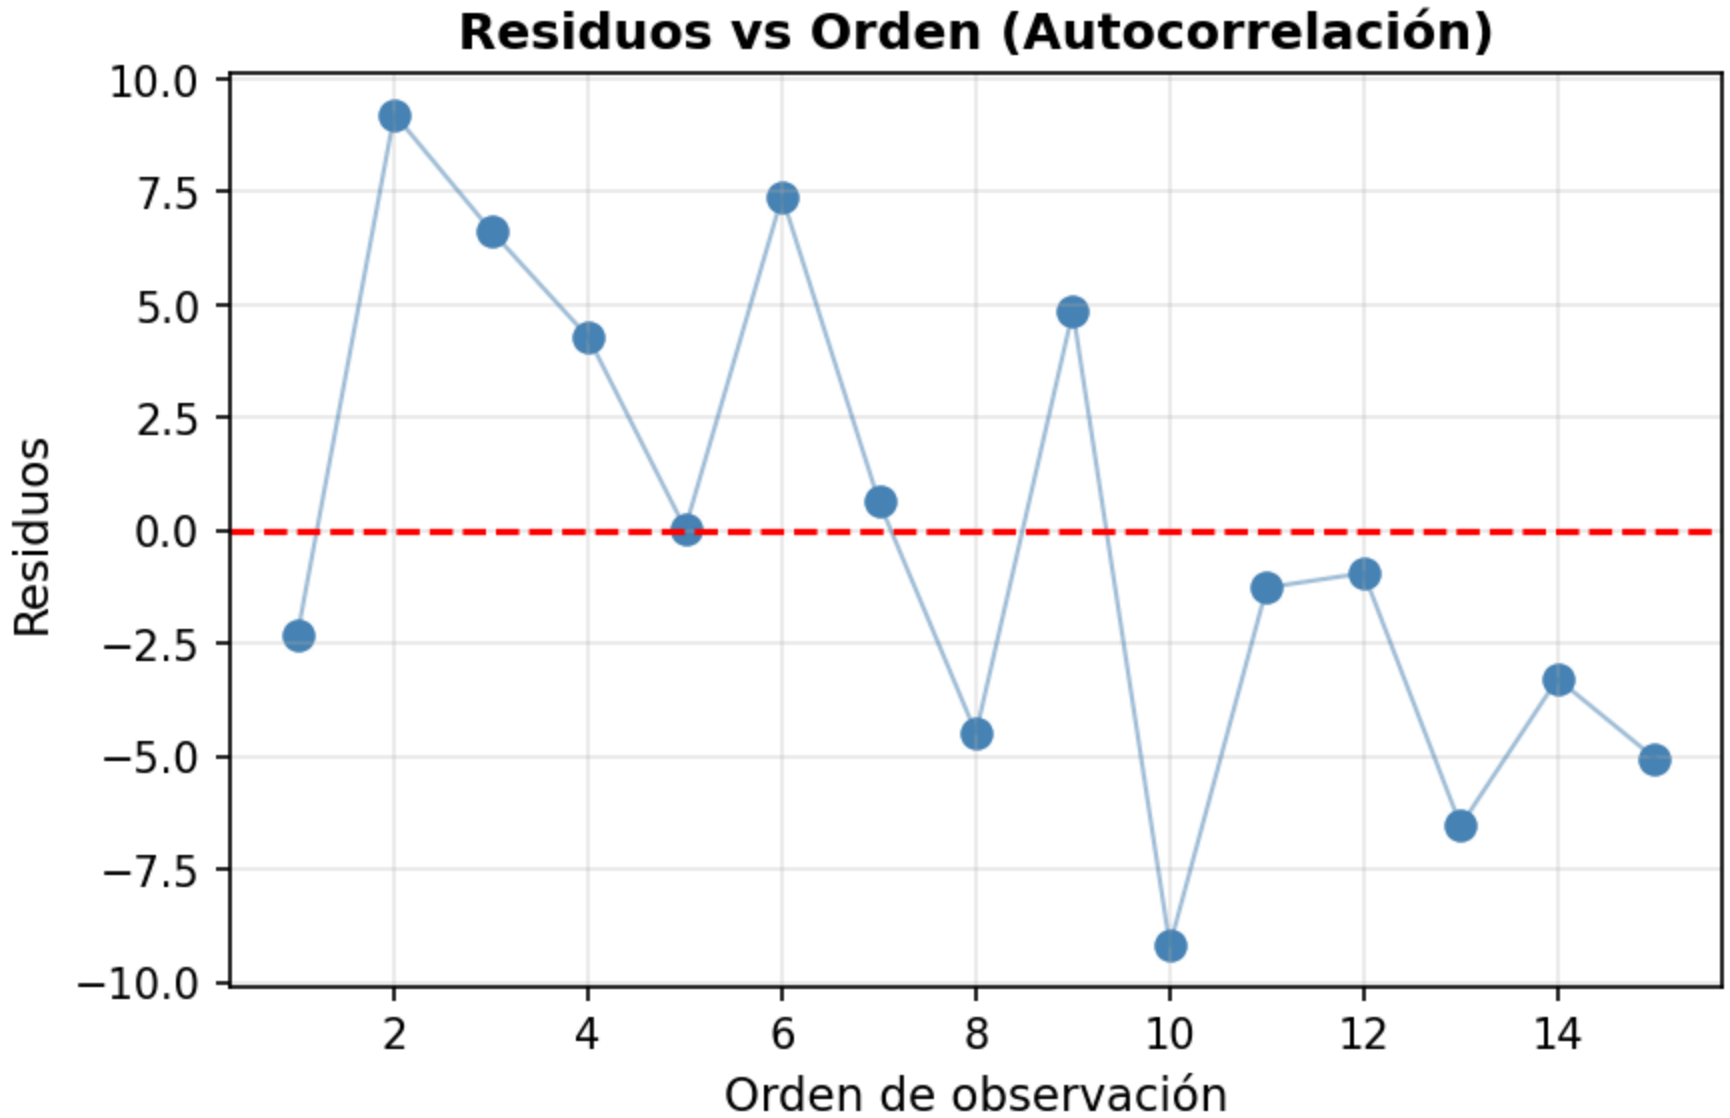

Scale-Location
√|Residuos estandarizados|
1.2
1.0
0.8
0.6
0.4
0.2
150
175
200
225
250
275
300
325
Valores ajustados

Diagnóstico: Residuos vs Orden (Autocorrelación)

- Suposición: los datos están ordenados temporalmente
- El orden en el que se obtienen de los datos no debe influir en los residuos
- Si hay un patrón (autocorrelación), puede indicar una dependencia temporal

```
residuos = modelo.resid
orden = range(1, len(residuos) + 1)

plt.scatter(orden, residuos)
plt.plot(orden, residuos, alpha=0.5)
plt.axhline(y=0, color='r', linestyle='--')
```


Residuos vs Orden (Autocorrelación)
Residuos
Orden de observación
10.0
7.5
5.0
2.5
0.0
−2.5
−5.0
−7.5
−10.0
2
4
6
8
10
12
14