Variables aleatorias y distribuciones

Modelos predictivos en el análisis de negocios

Profesor: Alberto Martín Izquierdo

Variables aleatorias

Variable aleatoria

- Función que asigna un valor numérico a cada resultado del experimento
- Traduce fenómenos reales a valores numéricos
- Las denotamos con letras mayúsculas: X, Y, Z, …
- Solo observamos los valores que toma la variable aleatoria: x, y, z, …
- Pueden ser **discretas** (p. ej. conteos) o **continuas** (p. ej. medidas)

Ejemplos

- Altura de una persona → 1.75
- Satisfacción de un cliente → 1
- Suma de dos dados: $(1, 3) \to 4$
- Clientes que entran cada día en promedio → 12.27
- Minutos entre dos autobuses → 6.47

Función de probabilidad

Describe qué valores de una variable aleatoria X ocurren con más frecuencia. Se escribe en minúscula: f.

Función de masa (PMF)

- Variables aleatorias **discretas**
- Indica la probabilidad de observar un valor concreto: $f(x) = P(X = x)$

Ejemplos:

- $P(\text{Satisfacción} = 1) = 0.85$
- $P(\text{Suma de dados} = 4) = \frac{3}{36} = \frac{1}{12}$

Función de densidad (PDF)

- Variables aleatorias **continuas**
- Indica la probabilidad de observar un valor en un intervalo: $P(a < X < b)$ es el **área bajo la curva** entre a y b

Ejemplos:

- $P(1.60 < \text{Altura} < 1.80) = 0.75$
- $P(\text{Espera} < 25) = 0.97$

Función de probabilidad: notas importantes

- La probabilidad de un valor que no está en el dominio de la variable aleatoria es 0
  - p. ej. $P(X = 0.5) = 0$ si X solo toma los valores 0 o 1
- La probabilidad de que una variable aleatoria continua tome un valor exacto es 0
- La probabilidad de una variable aleatoria continua se calcula sobre intervalos
- La probabilidad de un intervalo es el área bajo la función de densidad en ese intervalo (la calcula Python)

> En una variable continua, $f(x)$ **no** es una probabilidad: puede ser mayor que 1. Lo que vale como probabilidad es el área bajo la curva.

Función de distribución (CDF)

- Describe la probabilidad de observar un valor menor o igual que uno dado
- También llamada **función de distribución acumulada**
- Se escribe en mayúscula: F

$$F(x) = P(X \leq x)$$

Variables discretas

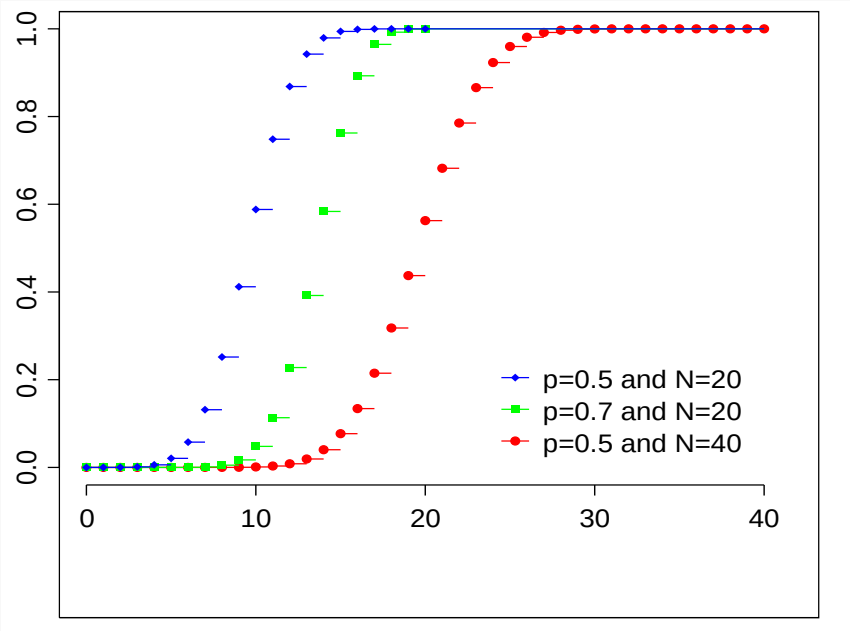
$$F(x) = \sum_{k \leq x} P(X = k)$$

Variables continuas

$F(x)$ es el área bajo la densidad a la izquierda de x

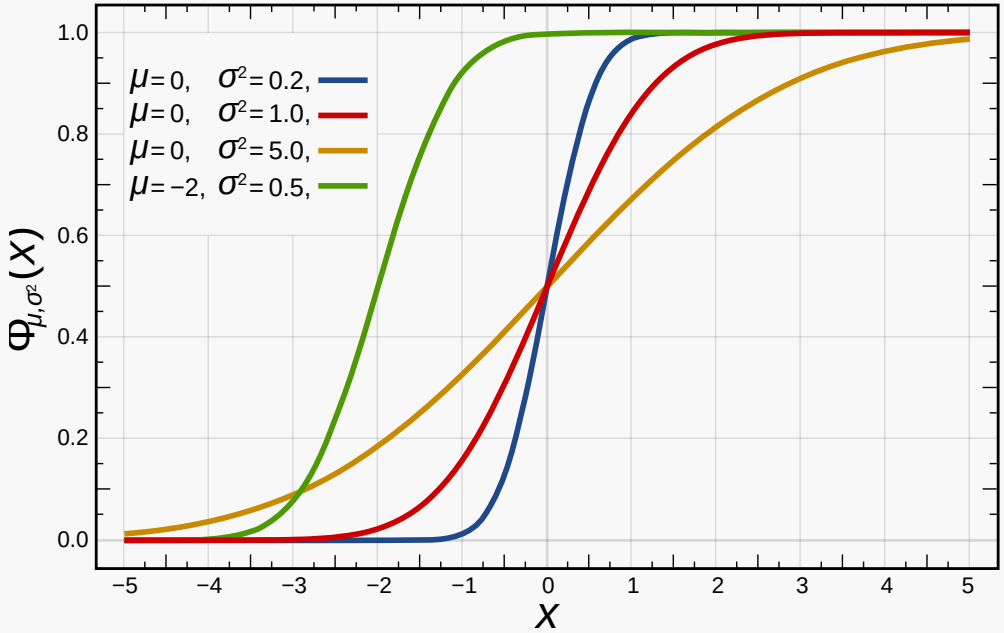
Función de distribución (CDF): ejemplos

Binomial (discreta)



Tayste, dominio público — Wikimedia Commons

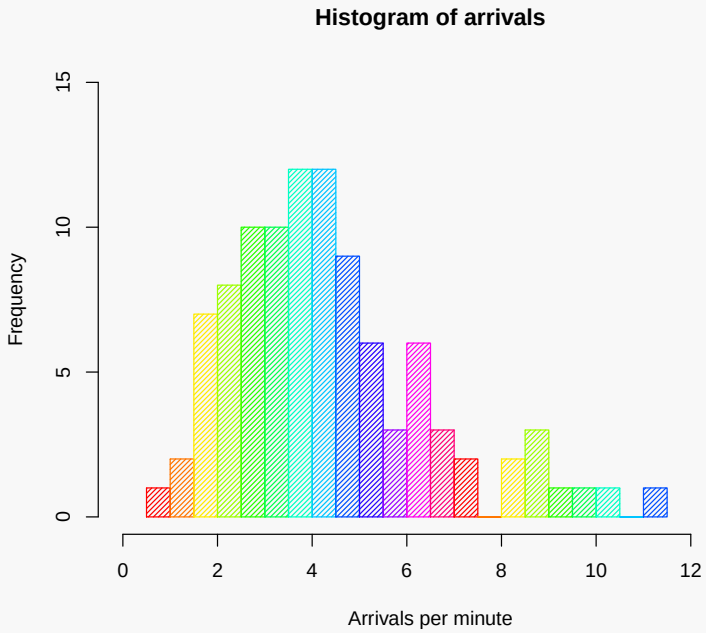
Normal (continua)



Inductiveload, dominio público — Wikimedia Commons

Distribución empírica (histograma)

- Distribución definida por una muestra observada
- Representa la frecuencia de los valores observados

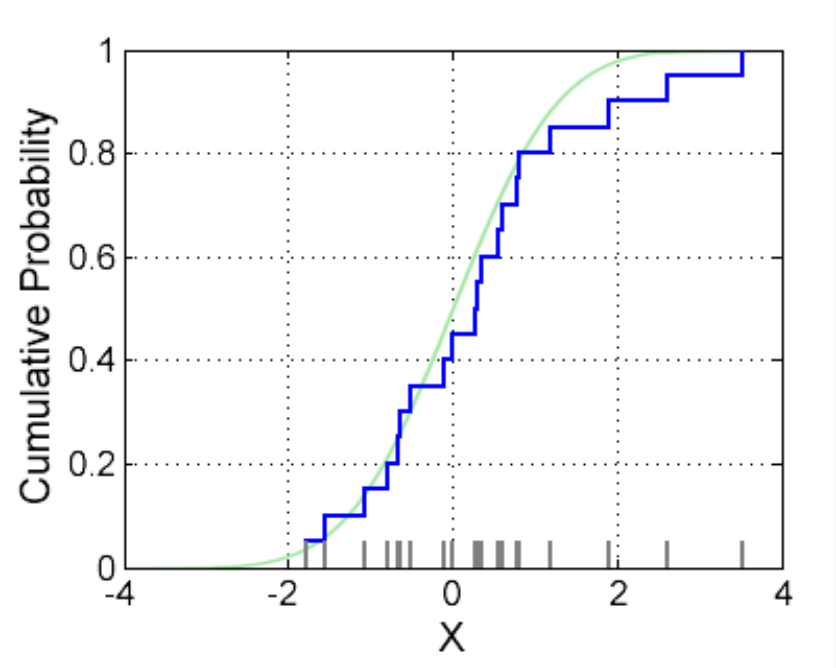


DanielPenfield, CC BY-SA 3.0 — Wikimedia Commons

Distribución empírica acumulada (ECDF)

- Función de distribución acumulada calculada a partir de los datos observados
- Útil para comparar con la distribución teórica

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n}$$



Bscan, CC0 — Wikimedia Commons

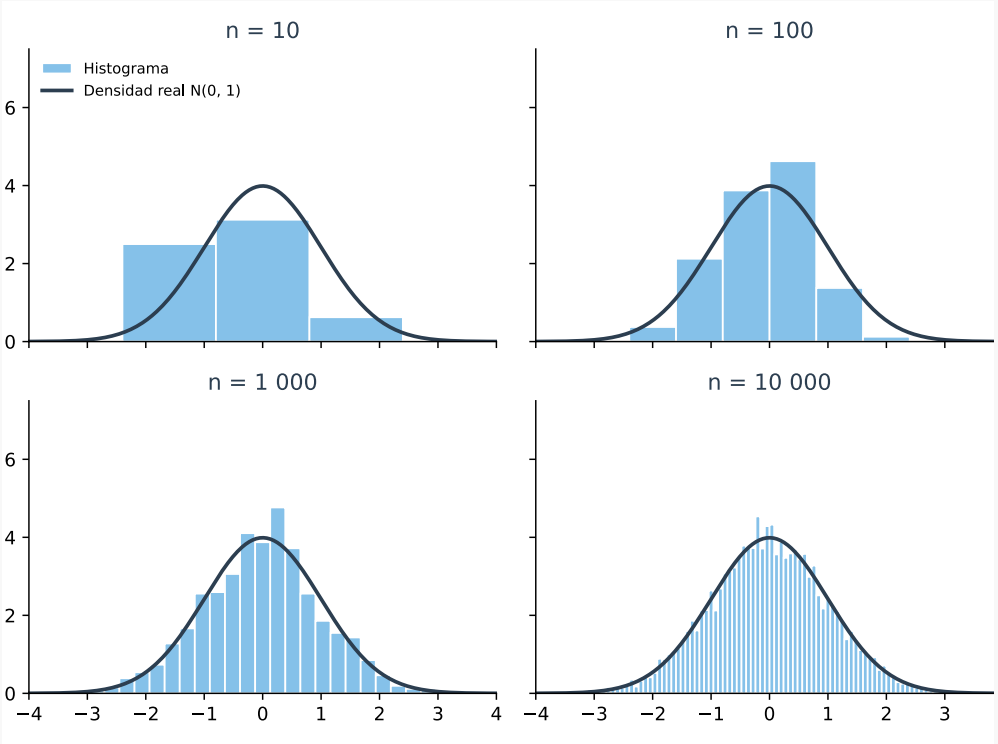
Teorema fundamental de la estadística

La distribución empírica converge a la distribución real cuando el tamaño de la muestra crece.

Si la muestra es suficientemente grande, podemos estimar los parámetros de la distribución real.

> Teorema de Glivenko–Cantelli: al crecer la muestra, la ECDF se pega a la CDF real en todos los puntos a la vez.

Versión interactiva en la web del curso



Histogramas de muestras $N(0,1)$ frente a la densidad real. Elaboración propia

Características de las distribuciones

X sigue una distribución con función de probabilidad f y función de distribución F:

- F empieza en 0 (muy a la izquierda) y termina en 1 (muy a la derecha); $f(x) \geq 0$ para todo x
- Si $x < y$, entonces $F(x) \leq F(y)$ (F es no decreciente)

Si X es discreta

$$\sum_{x} f(x) = 1$$

Si X es continua

El área total bajo la densidad vale 1

Media y varianza de una distribución

Media (esperanza)

Valor central: cada valor ponderado por su probabilidad.

- Discreta: $\mu = \mathbb{E}[X] = \sum_x x f(x)$
- Continua: la misma idea con la densidad (el centro de gravedad del área)

Varianza y desviación típica

Dispersión: media del cuadrado de las desviaciones respecto a la media.

- Discreta: $\sigma^2 = \mathbb{V}[X] = \sum_x (x - \mu)^2 f(x)$
- $\sigma = \sqrt{\sigma^2}$, en las unidades de la variable
- Atajo: $\mathbb{V}[X] = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2$

> Dos proveedores tardan de media 5 días: A en 4, 5 o 6 días ($\sigma = 0.82$) y B en 1, 5 o 9 días ($\sigma = 3.27$). Misma media, riesgos muy distintos.

Cuantiles

- **Cuantiles:** la función de distribución leída al revés: $q_p = F^{-1}(p)$, el valor que deja una probabilidad p por debajo.
- **Mediana** = cuantil 0.5. **Cuartiles** = cuantiles 0.25, 0.5 y 0.75. **Percentiles** = cuantiles 0.01, …, 0.99.
- **Rango intercuartílico:** IQR = $q_{0.75} - q_{0.25}$, la anchura del 50 % central.
- **Valores atípicos** (diagrama de caja): por debajo de $q_{0.25} - 1.5$ IQR o por encima de $q_{0.75} + 1.5$ IQR.

> En distribuciones asimétricas la media se va hacia la cola y la mediana no: diez salarios, uno de ellos de 400 000 €, tienen media 67 000 € y mediana 30 500 €.

Distribuciones

Distribuciones con nombre propio

Discretas	Continuas
Uniforme (discreta)	Uniforme (continua)
Bernoulli	Normal (gaussiana)
Binomial	
Poisson	

Uniforme discreta(a, b)

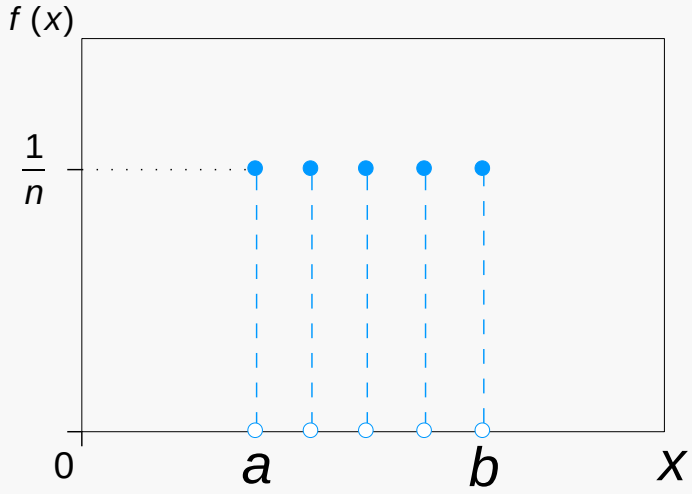
Modela $n = b - a + 1$ sucesos equiprobables entre los valores a y b (incluidos).

$$P(X = k) = \frac{1}{b - a + 1}, \quad k = a, a + 1, \ldots, b$$

Media	Varianza
$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$

Ejemplos

- Lanzamiento de dados, monedas, etc.
- Sorteos, loterías



IkamusumeFan, CC BY-SA 3.0 — Wikimedia Commons

Uniforme continua(a, b)

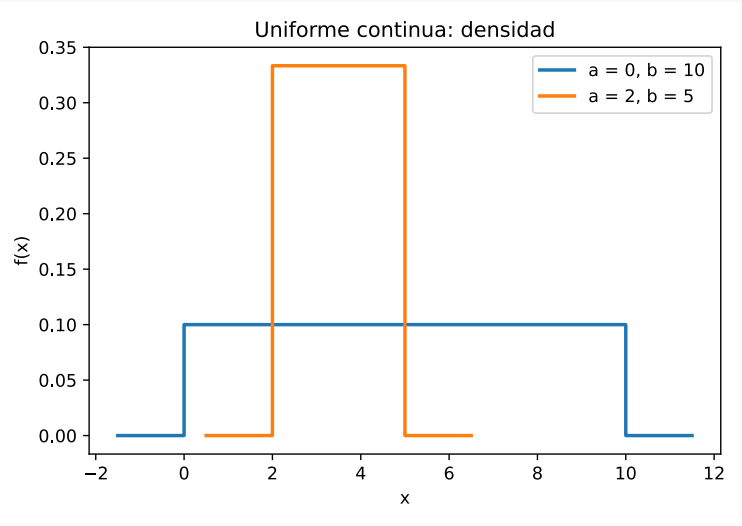
Cualquier valor entre a y b es igual de probable.

$$f(x) = \frac{1}{b-a}, \quad a \le x \le b$$

Media	Varianza
$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$

Ejemplos

- Tiempo de espera al metro si llegas sin mirar el horario
- Un coste del que solo conocemos el rango



Elaboración propia

Bernoulli(p)

Dos resultados posibles: $X = 0$ o $X = 1$

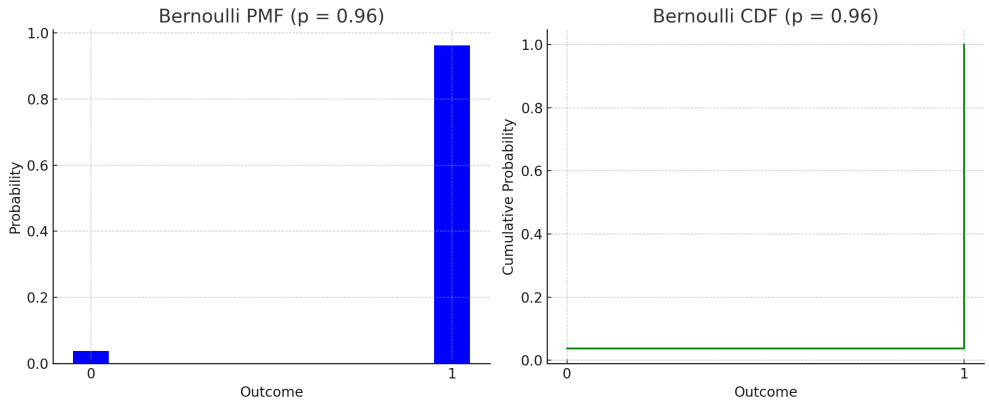
- 1 ocurre con probabilidad p
- 0 con probabilidad $q = 1 - p$

Media	Varianza
p	$p(1-p)$

Ejemplos

- Lanzamiento de una moneda
- Aprobar un examen
- Devolver un préstamo
- Cliente satisfecho o insatisfecho

$$P(X = k) = p^k(1-p)^{1-k}, \quad k \in \{0, 1\}$$



Acornellperson, CC0 — Wikimedia Commons

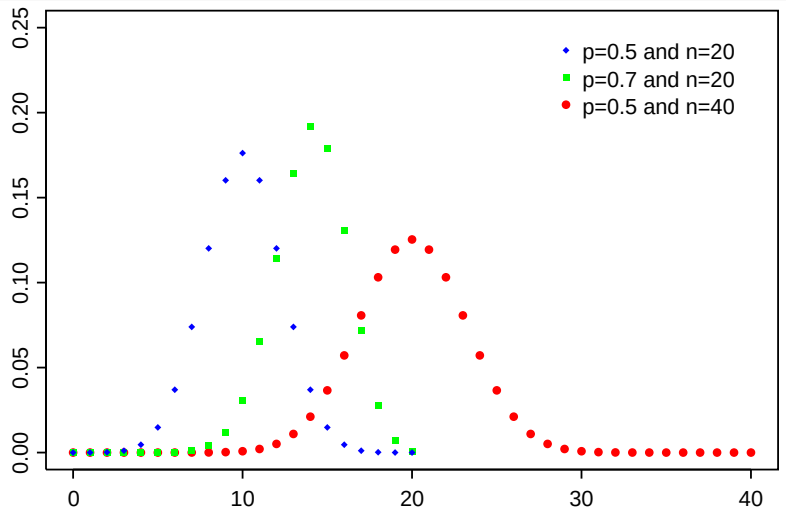
Binomial(n, p)

Suma de n experimentos Bernoulli(p) independientes.

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \ldots, n$$

Modela la probabilidad de observar k éxitos en n intentos.

Media	Varianza
np	$np(1-p)$



Tayste, dominio público — Wikimedia Commons

Ejemplos

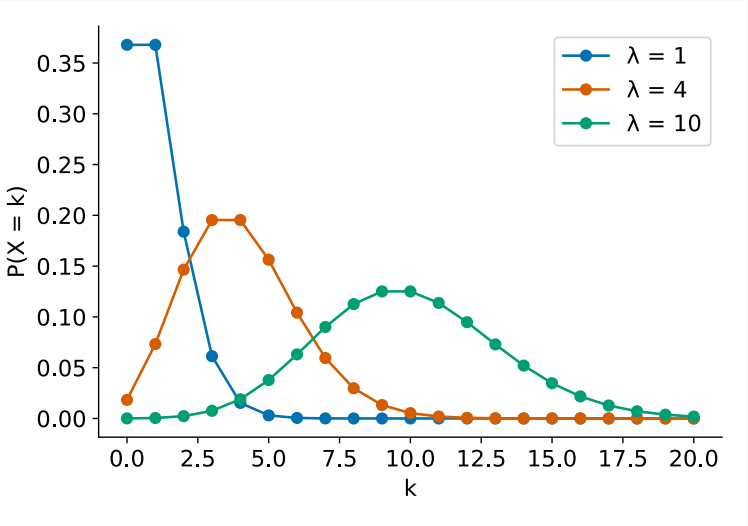
- Ensayos clínicos
- Conversión en marketing y ventas
- Control de calidad

Poisson(λ)

Número de eventos en un intervalo, a un ritmo medio constante λ.

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

Media	Varianza
λ	λ



Ejemplos

Número de veces que ocurre un evento en un intervalo de tiempo:

- Clientes que entran al día
- Llamadas recibidas cada día de 10 a 11
- Coches que pasan por minuto

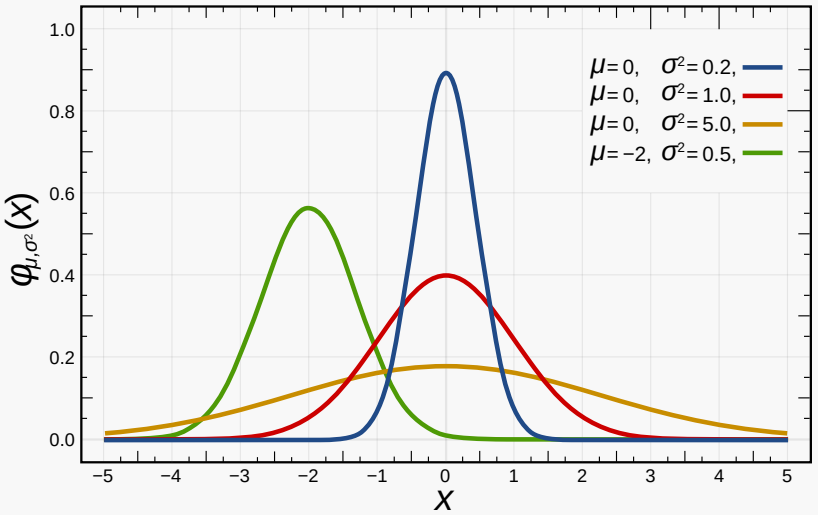
> La trabajarás en la entrega 1.

Distribución normal o gaussiana $N(\mu, \sigma^2)$

- Valores continuos en torno a un valor central μ
- La varianza σ^2 indica el grado de dispersión

Media	Varianza
μ	σ^2

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Inductiveload, dominio público — Wikimedia Commons

Ejemplos

- Presión arterial en un grupo de pacientes
- Errores de medición en experimentos científicos
- Teorema del límite central

Distribución normal estándar

- Caso particular de la normal con media $\mu = 0$ y varianza $\sigma^2 = 1$
- Se suele denotar como Z
- Si $X \sim N(\mu, \sigma^2)$, podemos transformarla en una variable aleatoria con distribución normal estándar (**tipificar**):

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

Recíprocamente, si $Z \sim N(0, 1)$, entonces:

$$\sigma Z + \mu \sim N(\mu, \sigma^2)$$

Variables aleatorias y distribuciones