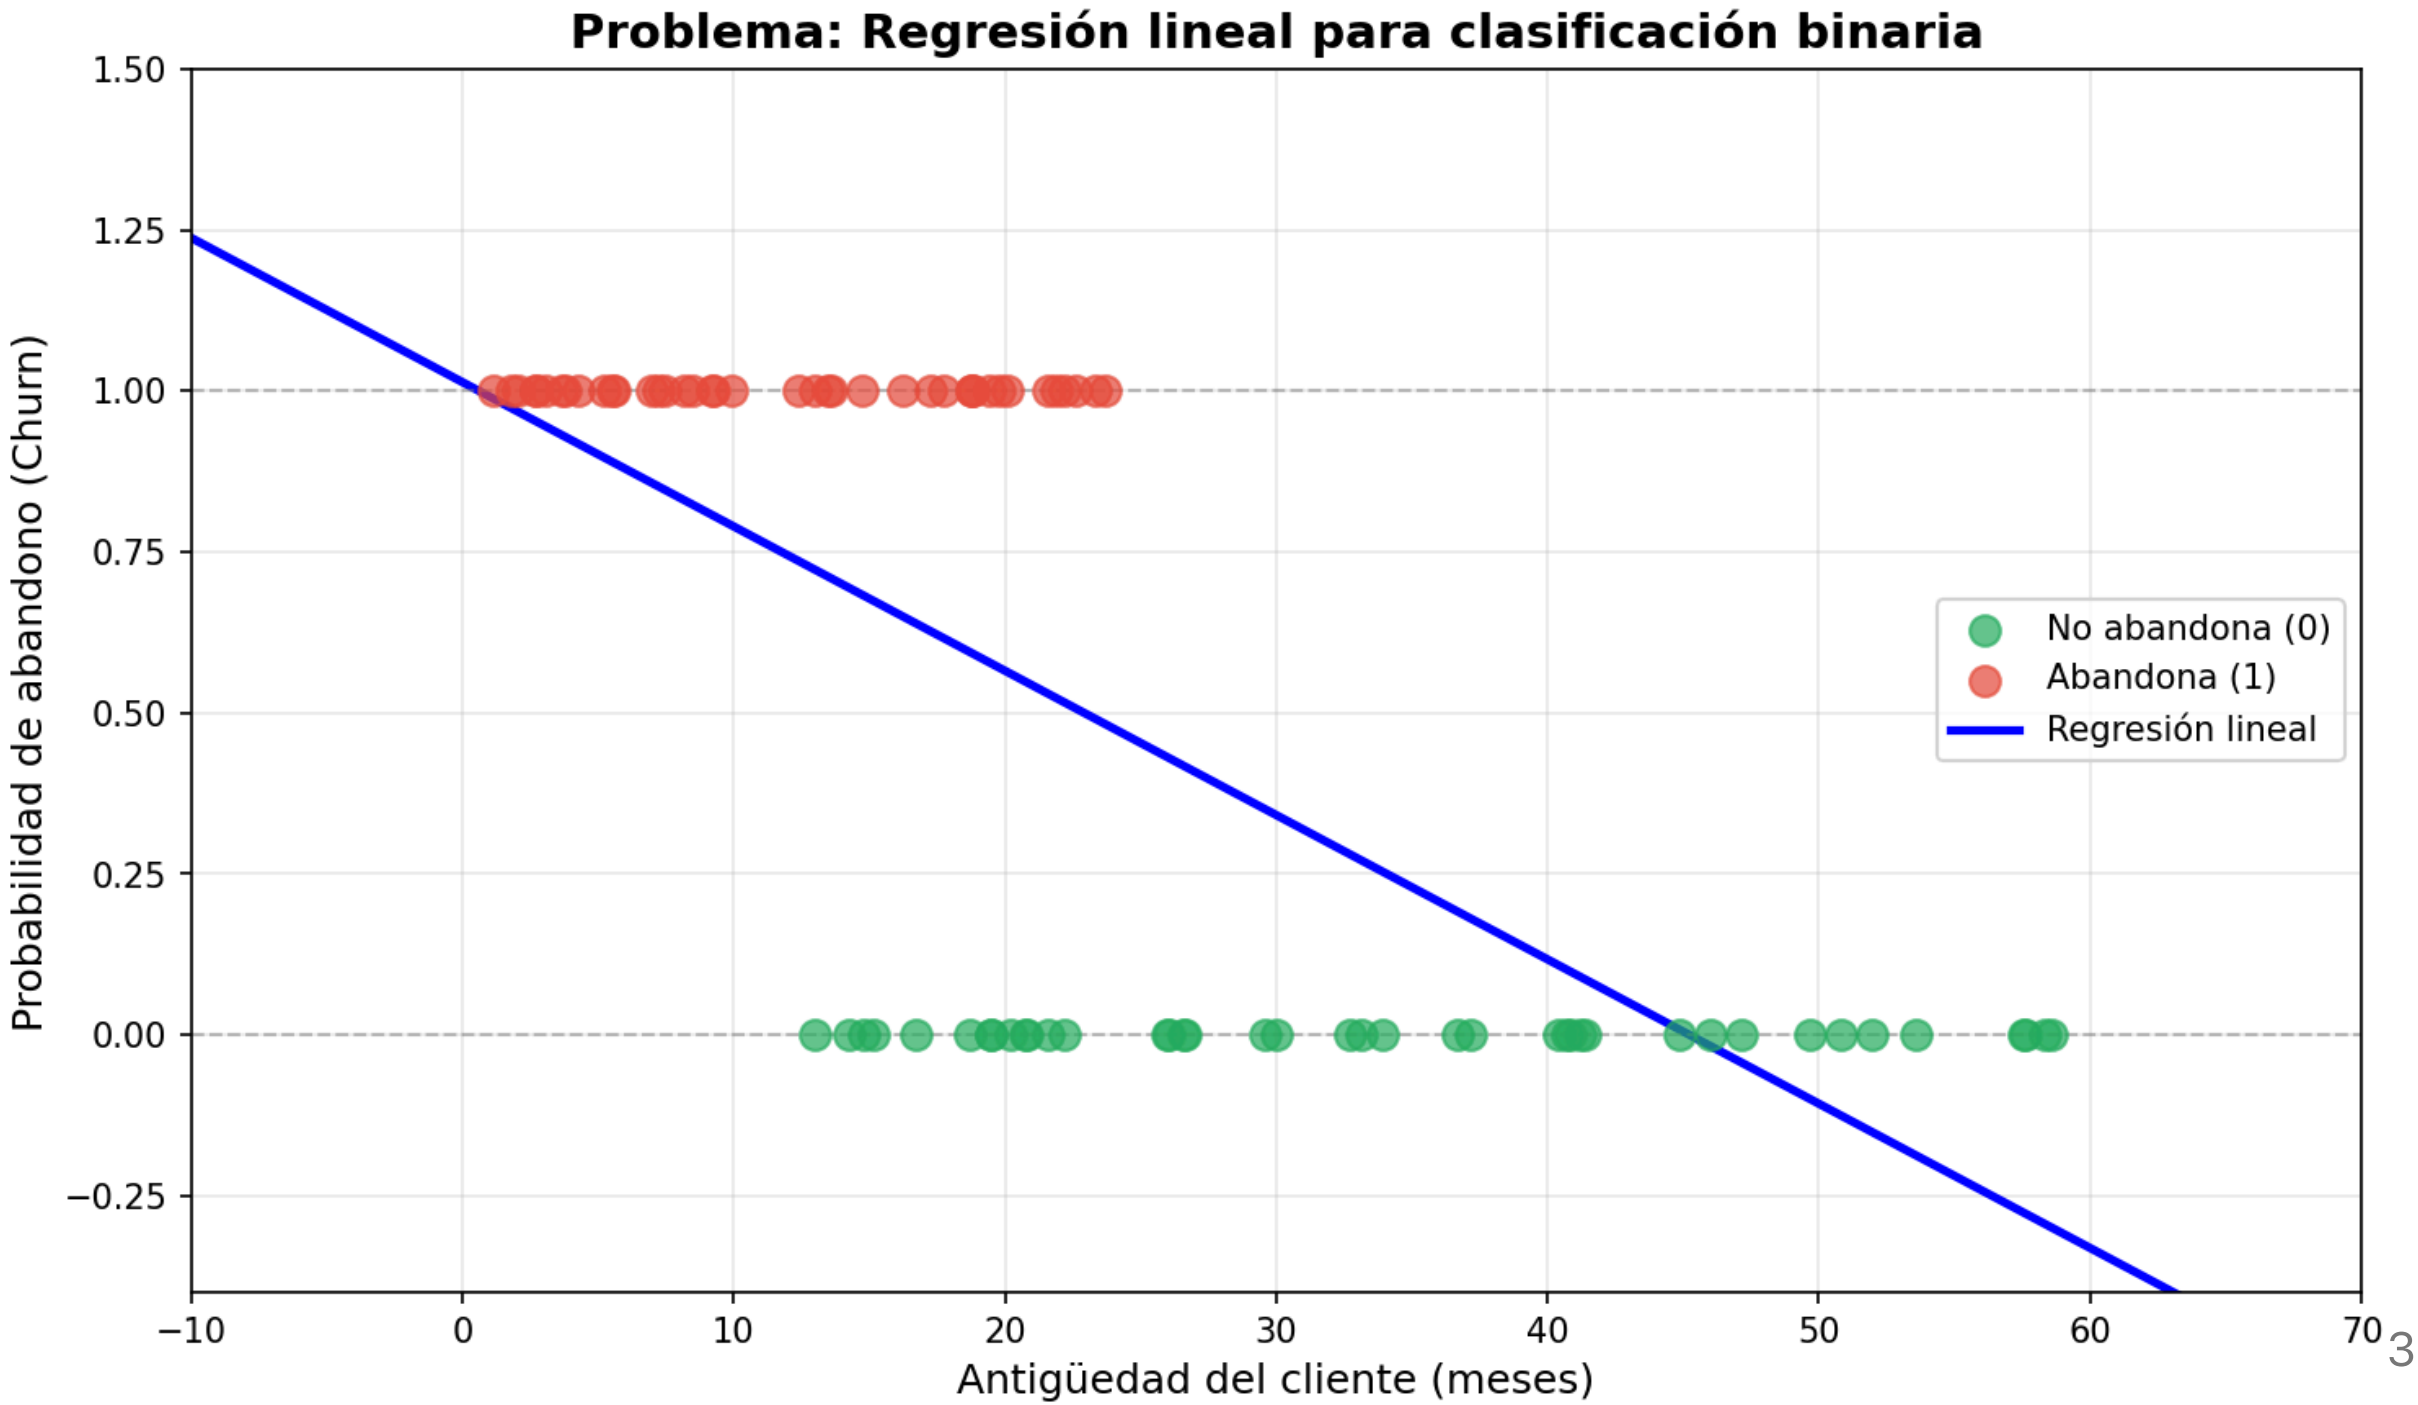
MODELOS PREDICTIVOS EN EL ANÁLISIS DE NEGOCIOS

Regresión Logística

¿Qué pasa si usamos regresión lineal para predecir variables binarias?

Ejemplo: Predecir si un cliente abandona (churn) según su antigüedad (meses)


Problema: Regresión lineal para clasificación binaria
Probabilidad de abandono (Churn)
Antigüedad del cliente (meses)
1.50
1.25
1.00
0.75
0.50
0.25
0.00
−0.25
−10
0
10
20
30
40
50
60
70
No abandona (0)
Abandona (1)
Regresión lineal

Predicciones con regresión lineal

Predicciones del modelo lineal

Antigüedad	Predicción	¿Es válido?
1 mes	1.05	**NO**
6 meses	0.85	?
12 meses	0.65	?
24 meses	0.40	?
48 meses	-0.05	**NO**
60 meses	-0.25	**NO**

Problemas:

La regresión lineal asume:

$$\hat{Y} = \beta_0 + \beta_1 X$$

- La recta **no tiene límites**
- Se extiende de $-\infty$ a $+\infty$
- La variable dependiente solo puede tomar valores 0 o 1
- ¿Qué hacemos con inválida?
- Qué hacemos con valores intermedios?

La solución: Adaptar la regresión lineal

Lo que queremos mantener:

La estructura lineal que ya conocemos:

$$Y = \beta_0 + \beta_1 X$$

- Interpretación de coeficientes
- Simplicidad del modelo
- Combinación lineal de variables

El problema:

Preducciones pueden ser cualquier número.

Pero necesitamos valores 0 o 1.

La idea:

Envolver la combinación lineal con una función que "comprima" el resultado al rango $[0, 1]$

La función de transformación

Interpretamos la predicción como probabilidad:

$$P(Y = 1) = f(\beta_0 + \beta_1 X)$$

Donde f es una función que transforma cualquier valor real a una probabilidad.

¿Qué función usar?

Necesitamos f tal que:

- $f(z) \to 0$ cuando $z \to -\infty$
- $f(z) \to 1$ cuando $z \to +\infty$
- Transición suave entre 0 y 1

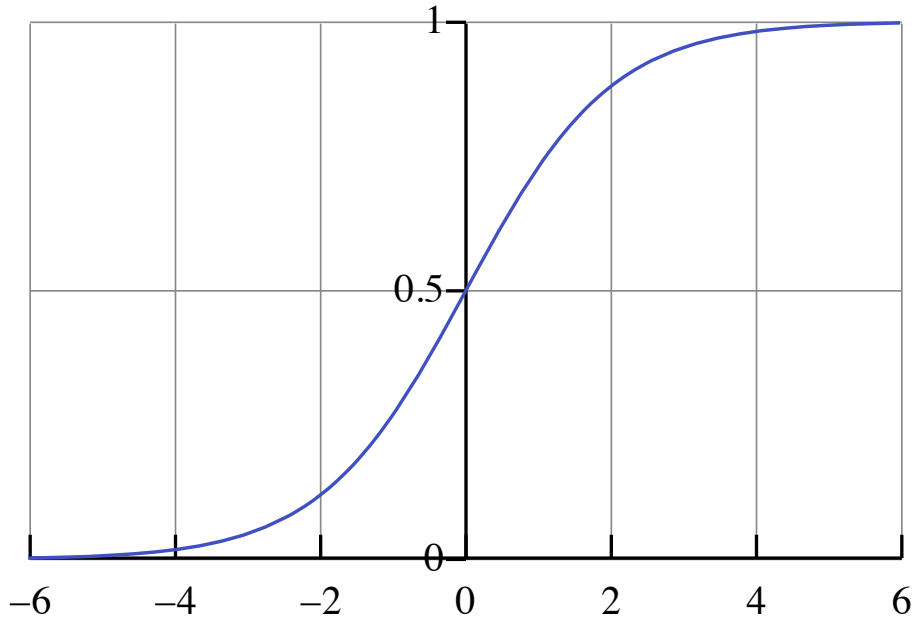
La función sigmoide

Función logística (sigmoide):

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Propiedades:

- Siempre entre 0 y 1
- Forma de "S" suave
- En $x = 0$: $\sigma(0) = 0.5$
- $x \to +\infty$: $\sigma(x) \to 1$
- $x \to -\infty$: $\sigma(x) \to 0$



By Qef - Public Domain

El modelo de regresión logística

Modelo:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$

O de forma más compacta:

$$P(Y = 1|X) = \sigma(\beta_0 + \beta_1 X)$$

Componentes:

- $P(Y = 1|X)$: Probabilidad del evento
- β_0: Intercepto
- β_1: Coeficiente de X
- X: Variable predictora

¿Qué hace el modelo?

1. Calcula un "score" lineal: $z = \beta_0 + \beta_1 X$
2. Lo transforma a probabilidad con la sigmoide

Predicción:

- Si $P(Y = 1) > T$ → Predecimos 1
- Si $P(Y = 1) \leq T$ → Predecimos 0

El umbral T se puede ajustar según necesidades

¿Cómo se entrena el modelo?

En regresión lineal:

Minimizamos el **error cuadrático medio (MSE)**:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- Funciona bien para valores continuos
- Penaliza errores grandes más que errores pequeños

En regresión logística:

El MSE **no funciona bien** porque:

- y_i solo puede ser 0 o 1
- $\hat{y}_i$ es una probabilidad entre 0 y 1
- La función de coste resultante no es convexa
- Dificulta encontrar el mínimo global

Necesitamos una función de pérdida diferente.

Log Loss (Entropía Cruzada Binaria)

Función de pérdida:

$$\text{Log Loss} = -\frac{1}{n}\sum_{i=1}^{n}[y_i \log(\hat{p}_i) + (1 - y_i)\log(1 - \hat{p}_i)]$$

donde:

- y_i: valor real (0 o 1)
- $\hat{p}_i$: probabilidad predicha

Interpretación:

- Si $y_i = 1$: penalizamos $-\log(\hat{p}_i)$
- Si $y_i = 0$: penalizamos $-\log(1 - \hat{p}_i)$

Comportamiento:

- Predicción correcta y segura: pérdida baja
- Predicción incorrecta y segura: pérdida muy alta
- Predicción insegura ($\hat{p} \approx 0.5$): pérdida moderada

Intuición del Log Loss

Cliente que SÍ abandona ($y = 1$)

Prob. predicha	Log Loss
0.99	0.01
0.90	0.11
0.70	0.36
0.50	0.69
0.10	2.30
0.01	4.61

Si predecimos baja probabilidad cuando el cliente abandona, el coste es muy alto.

Cliente que NO abandona ($y = 0$)

Prob. predicha	Log Loss
0.01	0.01
0.10	0.11
0.30	0.36
0.50	0.69
0.90	2.30
0.99	4.61

Si predecimos alta probabilidad cuando el cliente no abandona, el coste es muy alto.

De probabilidades a predicciones

El modelo produce probabilidades:

$$\hat{p} = P(\text{Churn} = 1 | X)$$

Necesitamos una decisión binaria:

- ¿Contactamos al cliente?
- ¿Aprobamos el crédito?
- ¿Enviamos la oferta?

El umbral (threshold):

$$\hat{y} = \begin{cases} 1 & \text{si } \hat{p} \geq T \\ 0 & \text{si } \hat{p} < T \end{cases}$$

Ejemplo: Campaña de retención

Cliente	P(Churn)	T=0.5	T=0.3
A	0.85	Contactar	Contactar
B	0.45	No contactar	Contactar
C	0.35	No contactar	Contactar
D	0.20	No contactar	No contactar

Con T=0.3 contactamos más clientes.

La pregunta es: ¿vale la pena?

La matriz de confusión

Compara las predicciones del modelo con los valores reales:

	Pred: No Churn	**Pred: Churn**
Real: No Churn	Verdadero Negativo (TN)	Falso Positivo (FP)
Real: Churn	Falso Negativo (FN)	Verdadero Positivo (TP)

Ejemplo: Campaña de retención

	Pred: No	Pred: Sí
Real: No	850	50
Real: Sí	30	70

- TN = 850: Clientes que no abandonan, bien clasificados
- FP = 50: Clientes estables que contactamos innecesariamente
- FN = 30: Clientes que perdemos por no actuar
- TP = 70: Clientes en riesgo que salvamos

Métricas derivadas de la matriz de confusión

Accuracy (Exactitud):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Proporción de predicciones correctas.

Problema: En clases desbalanceadas puede ser engañosa.

Precision (Precisión):

$$\text{Precision} = \frac{TP}{TP + FP}$$

De los que predigo positivos, ¿cuántos lo son realmente?

Métricas derivadas de la matriz de confusión

Recall (Sensibilidad o TPR):

$$\text{Recall} = \frac{TP}{TP + FN}$$

De los positivos reales, ¿cuántos detecto?

F1-Score:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Combina precision y recall en una sola métrica.

Tasas de clasificación

True Positive Rate (TPR):

$$\mathrm{TPR} = \frac{TP}{TP + FN}$$

False Positive Rate (FPR):

$$\mathrm{FPR} = \frac{FP}{FP + TN}$$

False Negative Rate (FNR):

$$\mathrm{FNR} = \frac{FN}{FN + TP} = 1 - \mathrm{TPR}$$

True Negative Rate (TNR):

$$\mathrm{TNR} = \frac{TN}{TN + FP} = 1 - \mathrm{FPR}$$

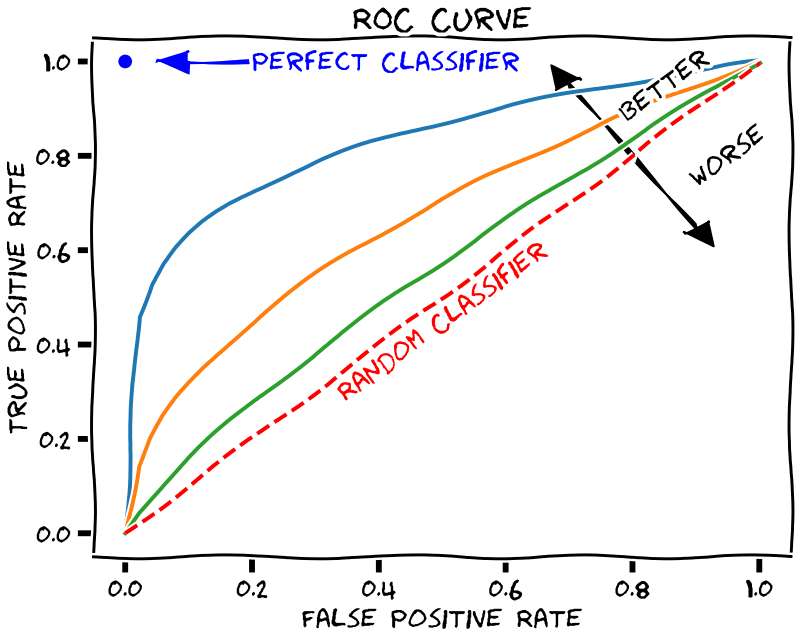
La curva ROC

Receiver Operating Characteristic

Representa TPR vs FPR para todos los umbrales posibles.

Construcción:

1. Ordenar predicciones por probabilidad
2. Para cada umbral T de 0 a 1:
    - Calcular punto (FPR, TPR)
3. Unir los puntos

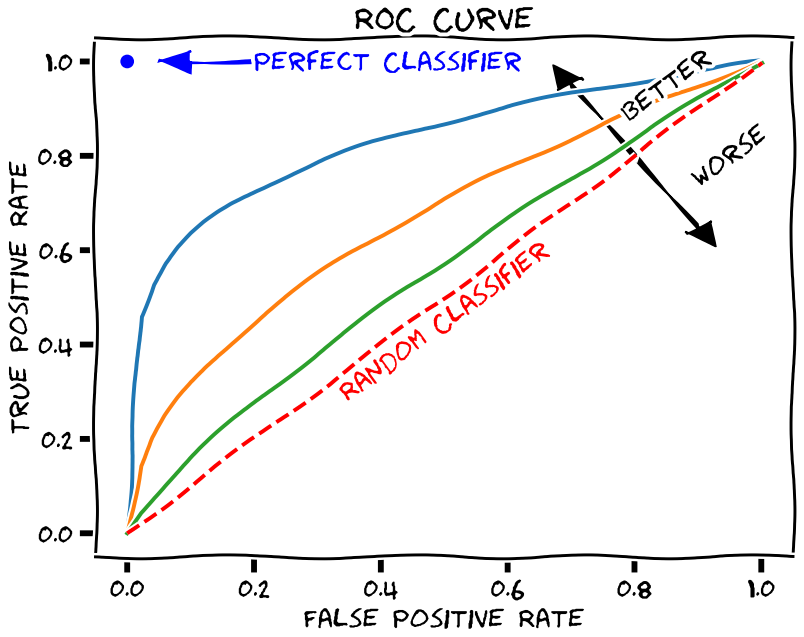


By MartinThoma - Own work, CC0

La curva ROC: Interpretación

Curvas típicas:

Modelo	Comportamiento
Perfecto	Pasa por (0,1)
Bueno	Por encima de diagonal
Aleatorio	Sigue la diagonal
Malo	Por debajo de diagonal



By MartinThoma - Own work, CC0

AUC: Área Bajo la Curva ROC

Definición:

Área bajo la curva ROC, entre 0 y 1.

Interpretación:

Probabilidad de que el modelo asigne mayor probabilidad a un positivo real que a un negativo real.

$$\text{AUC} = P(\hat{p}_{\text{positivo}} > \hat{p}_{\text{negativo}})$$

Valores de referencia:

AUC	Interpretación
1.0	Modelo perfecto
0.9 - 1.0	Excelente
0.8 - 0.9	Bueno
0.7 - 0.8	Aceptable
0.5 - 0.7	Pobre
0.5	Aleatorio

Métrica única que resume el rendimiento del modelo para todos los umbrales posibles.

Ejemplo: Métricas calculadas

Con la matriz anterior (T=0.5):

	Pred: No	**Pred: Sí**
Real: No	850	50
Real: Sí	30	70

- **Accuracy** = (850+70)/(850+50+30+70) = 92%
- **Precision** = 70/(70+50) = 58.3%
- **Recall** = 70/(70+30) = 70%
- **F1** = 2 × (0.583 × 0.70)/(0.583 + 0.70) = 63.6%

Interpretación de negocio:

- El 92% de predicciones son correctas
- De cada 100 clientes que contactamos, 58 realmente iban a abandonar
- Detectamos el 70% de los clientes en riesgo
- No detectamos el 30% de los clientes que abandonan

El trade-off entre Precision y Recall

Si bajamos el umbral (T=0.3):

- Clasificamos más casos como positivos
- **Recall aumenta**: detectamos más churners
- **Precision baja**: contactamos más clientes que no iban a abandonar
- Más falsos positivos, menos falsos negativos

Si subimos el umbral (T=0.7):

- Clasificamos menos casos como positivos
- **Recall baja**: perdemos más churners
- **Precision sube**: los que contactamos probablemente iban a abandonar
- Menos falsos positivos, más falsos negativos

No hay umbral perfecto:

Depende del coste de cada tipo de error para el negocio.

Ejemplo: Decisión de negocio

Contexto:

- Coste de perder un cliente: 500€
- Coste de retener (oferta): 100€
- 1000 clientes, 100 en riesgo real

Escenarios por cliente:

Situación	Acción	Coste
Se iba a ir	No contactar	500€
Se iba a ir	Contactar	100€
No se iba a ir	No contactar	0€
No se iba a ir	Contactar	100€

Ejemplo: Decisión de negocio

Umbral T=0.5:

- TP=70, FP=50, FN=30, TN=850
- Coste TP: 70 × 100€ = 7000€
- Coste FP: 50 × 100€ = 5000€
- Coste FN: 30 × 500€ = 15000€
- Coste TN: 850 × 0€ = 0€
- **Coste total: 27000€**

Umbral T=0.3:

- TP=90, FP=150, FN=10, TN=750
- Coste TP: 90 × 100€ = 9000€
- Coste FP: 150 × 100€ = 15000€
- Coste FN: 10 × 500€ = 5000€
- Coste TN: 750 × 0€ = 0€
- **Coste total: 29000€**

Ejemplo: Análisis del resultado

Comparación:

Umbral	Coste total
T=0.5	27000€
T=0.3	29000€

En este caso, T=0.5 es mejor.

¿Por qué?

- Reducir FN de 30 a 10 ahorra: 20 × 400€ = 8000€
- Pero aumentar FP de 50 a 150 cuesta: 100 × 100€ = 10000€

Conclusión:

El umbral óptimo depende de la relación entre costes:

$$\frac{\text{Coste FN}}{\text{Coste FP}} = \frac{500}{100} = 5$$

Si perder un cliente cuesta 5 veces más que contactar innecesariamente, debemos buscar un balance.

Con estos números, un umbral intermedio podría ser óptimo. En la práctica, se prueba con varios umbrales y se elige el que minimiza el coste total esperado.