Estimación e inferencia

Modelos predictivos en el análisis de negocios

Nebrija · MPAN

Estimación

Muestras frente a variables aleatorias

- **No** observamos la distribución de una variable aleatoria
- Observamos los valores que toma
- El conjunto de datos observados constituye una **muestra** de una población
- Podemos calcular **estadísticos** de una muestra (media, varianza, etc.)
- Denotamos las observaciones de una variable aleatoria X con letras minúsculas: $x_1, x_2, \ldots, x_n$

Media y varianza de una muestra

Media muestral

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Varianza muestral

$$s^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^2$$

Desviación típica muestral

$$s = \sqrt{s^2}$$

Cuasivarianza muestral

$$s^2_{n-1} = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \overline{x})^2$$

Estimador insesgado de σ^2.

> `pandas` `.var()` y `.std()` usan $\frac{1}{n-1}$ por defecto (`ddof=1`); `numpy` `np.var()` usa $\frac{1}{n}$ (`ddof=0`).

Estimadores de máxima verosimilitud

- Elegimos el valor del parámetro que hace **más probables los datos observados**
- Denotamos los parámetros estimados con un acento circunflejo: $\hat{p}$, $\hat{\lambda}$, $\hat{\mu}$

Modelo	**Parámetros**	**Estimador**
Bernoulli(p)	p	$\hat{p} = \overline{x}$ (proporción de unos)
Binomial(n, p)	p	$\hat{p} = \overline{x}/n$
Poisson(λ)	λ	$\hat{\lambda} = \overline{x}$
Normal$\left(\mu, \sigma^2\right)$	μ, σ	$\hat{\mu} = \overline{x}$, $\hat{\sigma} = s$ (con $1/n$)
Uniforme(a, b)	a, b	$\hat{a} = \min x_i$, $\hat{b} = \max x_i$

Ejemplo: campaña de email

- 500 emails al día; cada cliente compra con probabilidad p desconocida: Bernoulli (p)
- Ventas de un día: $X \sim \text{Binomial}(500, p)$, si los clientes son independientes y con la misma p
- En 30 días, 1094 ventas de 15 000 emails: $\hat{p} = 1094/15000 \approx 0.0729$
- Con el modelo estimado respondemos preguntas de negocio:

Perder dinero (menos de 30 ventas)

$$P(X \leq 29) = F(29) \approx 0.113$$

Saturar el almacén (más de 45)

$$P(X > 45) = 1 - F(45) \approx 0.064$$

> $\hat{p}$ es una estimación: con otros 30 días saldría otro valor. ¿Cuánto puede equivocarse?

Inferencia

Propiedades de la media y la varianza

Linealidad de la esperanza

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

Varianza de una variable escalada

$$\mathbb{V}[aX + b] = a^2\mathbb{V}[X]$$

Varianza de la suma

Si X e Y son independientes:

$$\mathbb{V}[X + Y] = \mathbb{V}[X] + \mathbb{V}[Y]$$

Aplicadas a la media de n observaciones independientes, $\overline{X} = \frac{1}{n}\left(X_1 + \cdots + X_n\right)$, dan su media y su varianza.

Distribuciones muestrales

- Distribuciones de los estadísticos calculados a partir de muestras aleatorias
- Permiten inferir propiedades de la población a partir de la muestra
- Ejemplo: distribución muestral de la media de n observaciones independientes

$$\mathbb{E}[\overline{X}] = \mu, \quad \mathbb{V}[\overline{X}] = \frac{\sigma^2}{n}$$

- Nos ayudan a construir intervalos de confianza y realizar contrastes de hipótesis

Ley de los grandes números

- Si $X_1, X_2, \ldots$ son independientes y con la misma distribución de media μ, la media muestral se acerca a μ cuando n crece:

$$\overline{X}_n \approx \mu \quad \text{para } n \text{ grande}$$

- Justifica estimar probabilidades con frecuencias: la proporción de compras se acerca a p
- El **error estándar** $\sigma/\sqrt{n}$ mide cuánto se aleja aún con n finito

> No «compensa» las rachas: los datos nuevos las diluyen.

Teorema del límite central

- La distribución de la media muestral se aproxima a una distribución normal
- Independientemente de la distribución original de la variable aleatoria (basta con que tenga varianza finita)
- La aproximación mejora a medida que aumenta el tamaño de la muestra
- En fórmula:

$$\overline{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{para } n \text{ grande}$$

- Es fundamental para la inferencia estadística

Aproximación normal de la binomial

- Una binomial es una suma de n Bernoulli independientes. Por el TLC:

$$\text{Binomial}(n, p) \approx N(np, np(1-p)) \quad \text{si } np \geq 5 \text{ y } n(1-p) \geq 5$$

- **Corrección de continuidad:** $P(X \leq k) \approx P(Y \leq k + 0.5)$

> Campaña de email: $P(X \leq 29) = 0.113$ exacta, **0.115** con la normal corregida y **0.100** sin corregir.

Intervalos de confianza

- Rango de valores en el que se espera encontrar un parámetro poblacional con un nivel de confianza dado
- Se construyen a partir de la distribución muestral del estadístico
- Ejemplo: intervalo de confianza para la media poblacional (muestras grandes)

$$\overline{x} \pm z_{\alpha/2} \frac{s}{\sqrt{n}}$$

- $z_{\alpha/2}$ es el valor crítico de la normal estándar: $P\left(Z > z_{\alpha/2}\right) = \alpha/2$

> Para un 95 % de confianza, $\alpha = 0.05$ y $z_{0.025} \approx 1.96$. Con muestras pequeñas se usa la t de Student.