Estimación e inferencia

Modelos predictivos en el análisis de negocios

Nebrija · MPAN

Estimación

Muestras frente a variables aleatorias

- **No** observamos la distribución de una variable aleatoria
- Observamos los valores que toma
- El conjunto de datos observados constituye una **muestra** de una población
- Podemos calcular **estadísticos** de una muestra (media, varianza, etc.)
- Denotamos las observaciones de una variable aleatoria X con letras minúsculas: $x_1, x_2, \ldots, x_n$

Estadísticos de una muestra

Media muestral

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Varianza muestral

$$s^2 = \frac{1}{n}\sum_{i=1}^{n} (x_i - \overline{x})^2$$

Desviación típica muestral

$$s = \sqrt{s^2}$$

Cuasivarianza muestral

$$s^2_{n-1} = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \overline{x})^2$$

Estimador insesgado de σ^2.

> `pandas .var()` y `.std()` usan $\frac{1}{n-1}$ por defecto (`ddof=1`); `numpy np.var()` usa $\frac{1}{n}$ (`ddof=0`).

Mediana muestral

Valor central de la muestra ordenada.

Inferencia

Método de los momentos

- Técnica para estimar los parámetros de una distribución a partir de una muestra
- Igualamos los momentos teóricos de la distribución con los momentos muestrales

Primer momento (media)

$$\mu = \mathbb{E}[X] \approx \overline{x}$$

Segundo momento (varianza)

$$\sigma^2 = \mathbb{V}[X] \approx s^2$$

- Denotamos los parámetros estimados con un acento circunflejo: $\hat{\mu}$, $\hat{\sigma}^2$

Ejemplo: para una Poisson(λ), como $\mathbb{E}[X] = \lambda$, estimamos $\hat{\lambda} = \overline{x}$.

Distribuciones muestrales

- Distribuciones de los estadísticos calculados a partir de muestras aleatorias
- Permiten inferir propiedades de la población a partir de la muestra
- Ejemplo: distribución muestral de la media de n observaciones independientes

$$\mathbb{E}[\overline{X}] = \mu, \quad \mathbb{V}[\overline{X}] = \frac{\sigma^2}{n}$$

- Nos ayudan a construir intervalos de confianza y realizar contrastes de hipótesis

Teorema del límite central

- La distribución de la media muestral se aproxima a una distribución normal
- Independientemente de la distribución original de la variable aleatoria (basta con que tenga varianza finita)
- La aproximación mejora a medida que aumenta el tamaño de la muestra
- Formalmente:

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \to N(0,1) \quad \text{cuando } n \to \infty$$

- Es fundamental para la inferencia estadística

Intervalos de confianza

- Rango de valores en el que se espera encontrar un parámetro poblacional con un nivel de confianza dado
- Se construyen a partir de la distribución muestral del estadístico
- Ejemplo: intervalo de confianza para la media poblacional (muestras grandes)

$$\overline{x} \pm z_{\alpha/2} \frac{s}{\sqrt{n}}$$

- $z_{\alpha/2}$ es el valor crítico de la normal estándar: $P\left(Z > z_{\alpha/2}\right) = \alpha/2$

> Para un 95 % de confianza, $\alpha = 0.05$ y $z_{0.025} \approx 1.96$. Con muestras pequeñas se usa la t de Student.