Regresión lineal simple

Modelos predictivos en el análisis de negocios

Nebrija · MPAN

¿Por qué regresión lineal?

Hasta ahora

- Variables aleatorias individuales
- Distribuciones univariadas
- Estadísticos descriptivos
- Probabilidades e incertidumbre

Ahora

- **Relaciones entre variables**
- ¿Cómo afecta X a Y?
- Predicción y modelado

Preguntas de negocio

- ¿Cuánto aumentan las ventas por cada euro invertido en publicidad?
- ¿Cómo afecta la temperatura a la demanda de helados?
- ¿Qué salario esperamos para alguien con 10 años de experiencia?
- ¿Cuál será el precio de una vivienda de 100 m^2?

Dependencia entre variables aleatorias

Recordemos que dos variables X e Y pueden estar relacionadas:

Variables independientes

$$P(X, Y) = P(X) \cdot P(Y)$$

Conocer el valor de X no nos da información sobre Y.

Ejemplos: lanzamiento de dos dados; color de ojos y horas de sueño; tener mascota y preferencia por el té.

Variables dependientes

$$P(X, Y) \neq P(X) \cdot P(Y)$$

Conocer el valor de X nos ayuda a predecir Y.

Ejemplos: estudio y nota del examen; inversión en marketing y ventas; temperatura y consumo de helados.

Covarianza y correlación

Covarianza

Mide cómo varían dos variables conjuntamente:

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Estimación muestral:

$$\hat{\mathrm{Cov}}(X, Y) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

- $\mathrm{Cov} > 0$: relación positiva
- $\mathrm{Cov} < 0$: relación negativa
- $\mathrm{Cov} = 0$: sin relación lineal

Correlación de Pearson

Covarianza normalizada entre -1 y 1:

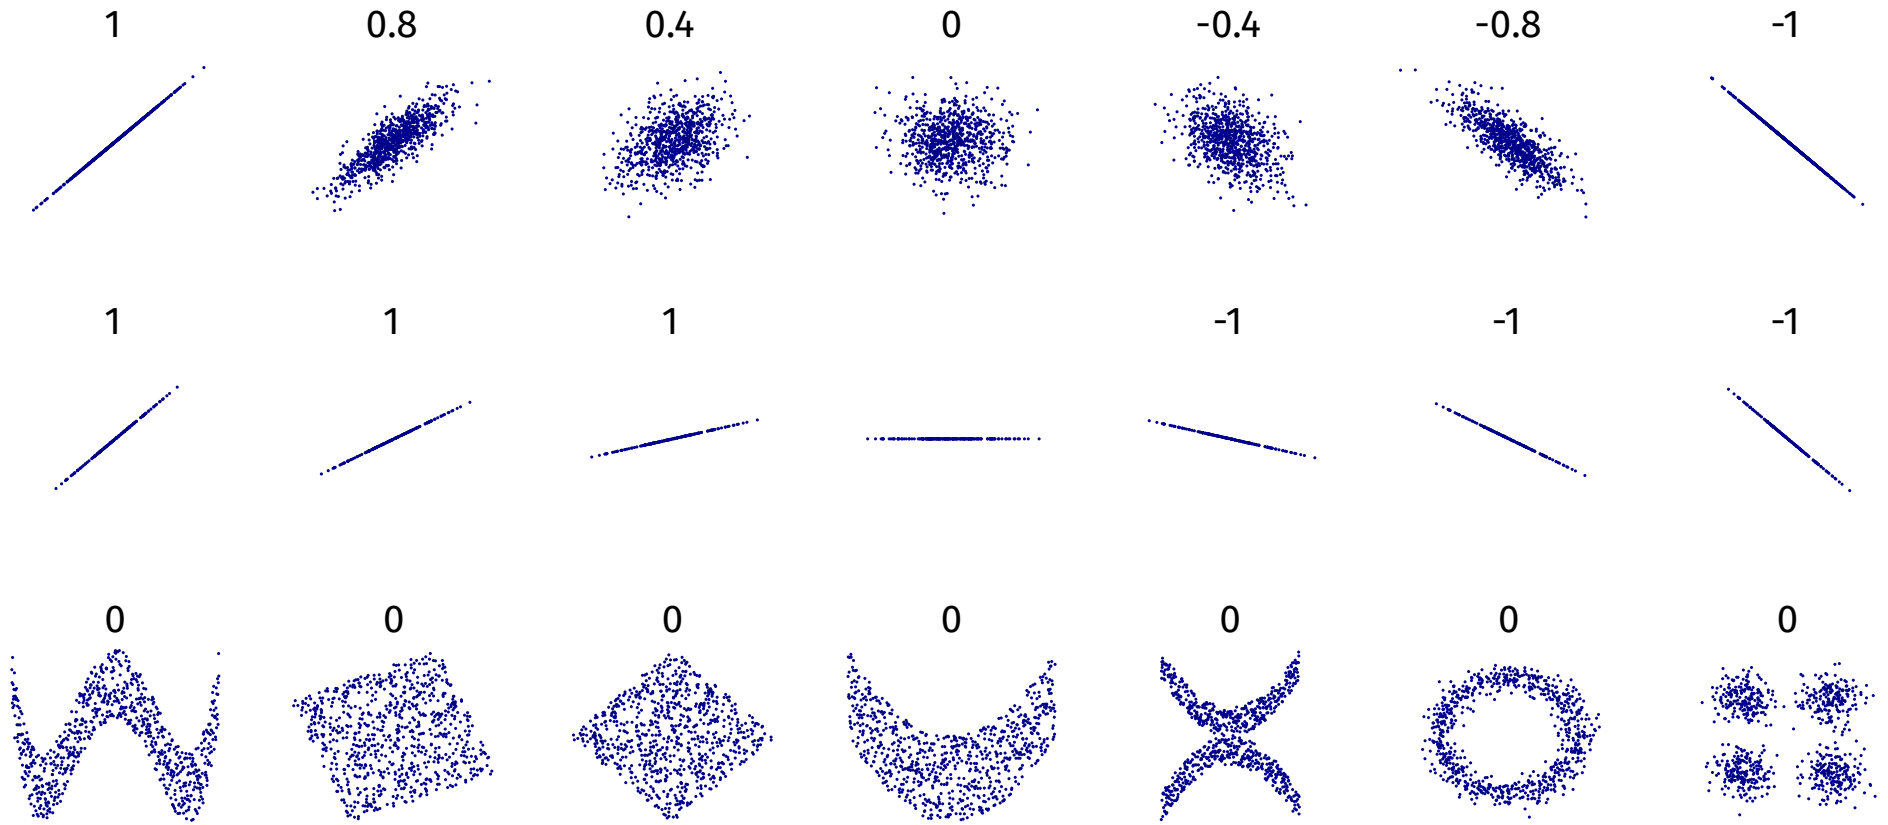
$$\rho(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Estimación muestral:

$$r = \frac{\hat{\mathrm{Cov}}(X, Y)}{s_X s_Y}$$

- $r = 1$: correlación positiva perfecta
- $r = -1$: correlación negativa perfecta
- $r = 0$: sin correlación lineal

Interpretación de la correlación



DenisBoigelot, CC0 — Wikimedia Commons

Correlación no implica causalidad

⚠️ Que dos variables se muevan juntas no significa que una cause la otra.

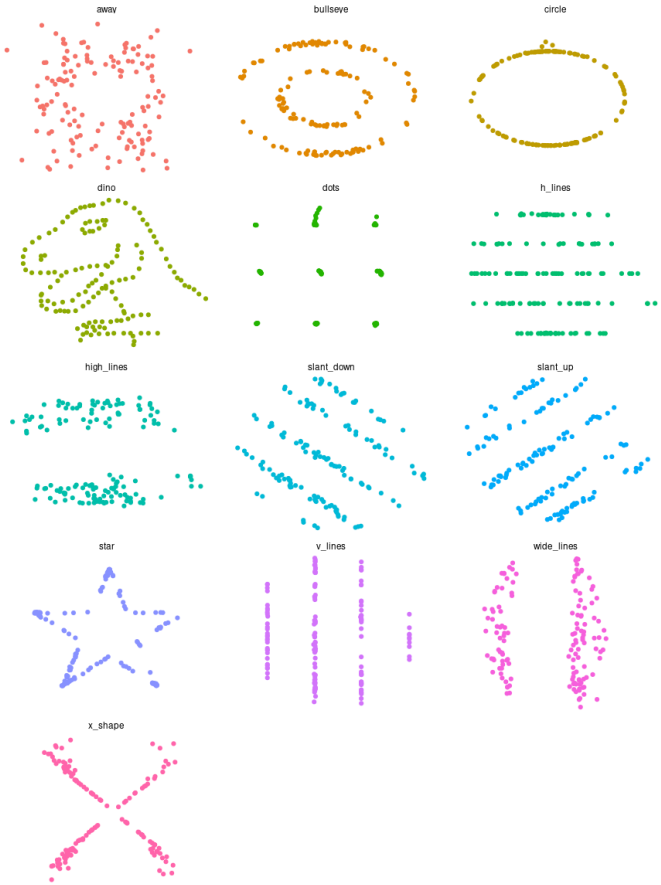
Relaciones espurias — tylervigen.com

Ausencia de correlación no implica independencia

Todos estos conjuntos de datos tienen **la misma media, varianza y correlación**… y son completamente distintos.

> Visualiza siempre los datos antes de resumirlos.

Datasaurus Dozen — Jumping Rivers / datasauRus



Del análisis descriptivo al predictivo

Descriptivo vs. predictivo

Análisis descriptivo

- Calcular estadísticos
- Visualizar datos
- Correlaciones
- **¿Qué ha pasado?**

Análisis predictivo

- Construir modelos
- Hacer predicciones
- Cuantificar relaciones
- **¿Qué pasará?**

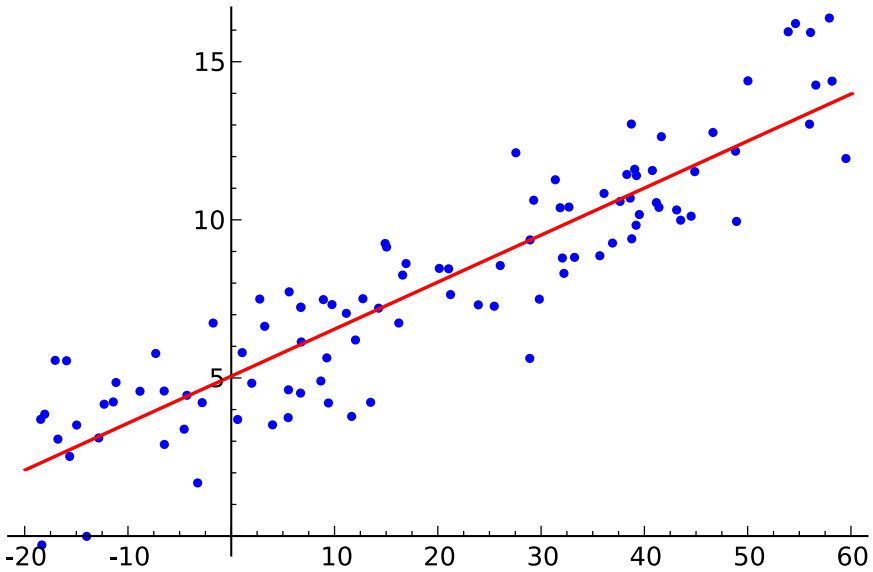
La regresión conecta ambos enfoques

1. **Describir** la relación entre variables
2. **Predecir** valores futuros
3. **Cuantificar** el efecto de una variable sobre otra

¿Qué es la regresión lineal?

- Modelo estadístico para la relación entre variables
- **Asume** una relación **lineal** entre X e Y
- Busca la recta que mejor se ajusta a los datos
- Ecuación de la recta:

$$y = \beta_0 + \beta_1 x$$



Sewaqu, dominio público — Wikimedia Commons

Modelo de regresión lineal simple

Ecuación del modelo

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Predicción

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$$

Componentes

- Y: variable dependiente (respuesta)
- X: variable independiente (predictor)
- β_0: **intercepto** (ordenada en el origen)
- β_1: **pendiente** (efecto de X sobre Y)
- ε: **error aleatorio**

Interpretación de los parámetros

Intercepto (β_0)

- Valor esperado de Y cuando $X = 0$
- No siempre tiene interpretación práctica

Ejemplo: si $\beta_0 = 25000$, el salario base sin experiencia es 25 000 €.

Pendiente (β_1)

- Cambio en Y por cada unidad de aumento en X
- **Interpretación clave** del modelo

Ejemplo: si $\beta_1 = 1500$, cada año de experiencia aumenta el salario en 1500 €.

Predicción

$$\text{Salario} = 25000 + 1500 \times \text{Años de experiencia}$$

Para alguien con 5 años: $\hat{Y} = 25000 + 1500 \times 5 = 32500$ €.

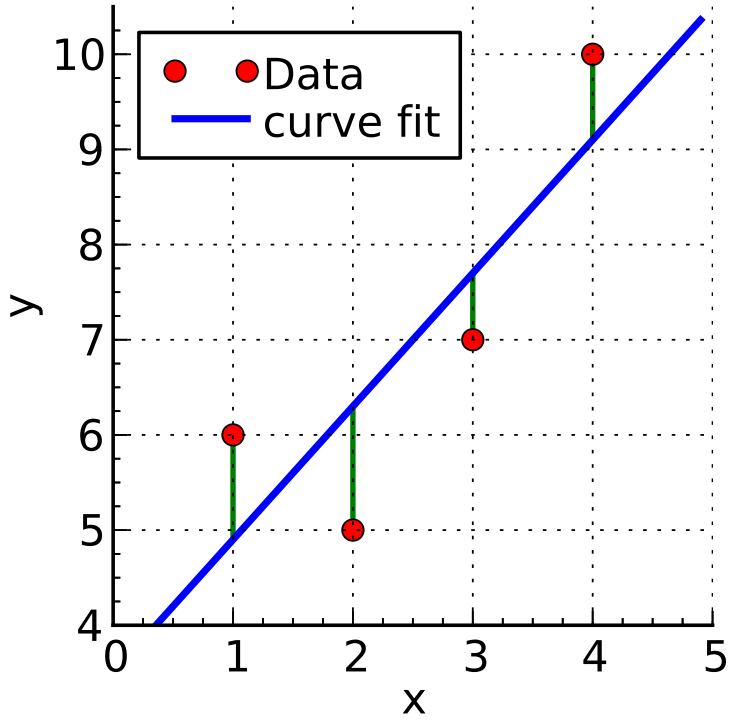
El error aleatorio (ε)

¿Por qué hay error?

- Variabilidad natural del fenómeno
- Variables no incluidas en el modelo
- Errores de medición

Supuestos sobre ε

1. **Media cero:** $\mathbb{E}[\varepsilon] = 0$
2. **Varianza constante:** $\mathbb{V}(\varepsilon) = \sigma^2$ (homocedasticidad)
3. **Normalidad:** $\varepsilon \sim N(0, \sigma^2)$
4. **Independencia**



Krishnavedala, CC0 — Wikimedia Commons

Las líneas verticales son los residuos

Estimación por mínimos cuadrados (OLS)

Objetivo

Encontrar $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimicen la suma de los errores al cuadrado:

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Esta es la **función de pérdida** o **función de coste**.

> La recta de regresión siempre pasa por el punto $(\overline{x}, \overline{y})$.

Relación entre correlación y regresión

La pendiente de la regresión está directamente relacionada con la correlación:

$$\hat{\beta}_1 = r \frac{s_Y}{s_X}$$

donde r es el coeficiente de correlación y s_Y, s_X las desviaciones típicas.

Implicaciones

- Si $r = 0 \Longrightarrow \hat{\beta}_1 = 0$ (sin relación lineal)
- Si $r > 0 \Longrightarrow \hat{\beta}_1 > 0$ (relación positiva)
- Si $r < 0 \Longrightarrow \hat{\beta}_1 < 0$ (relación negativa)
- Mayor $|r| \Longrightarrow$ mayor $|\hat{\beta}_1|$ (relación más fuerte)

Residuos

Definición

Diferencia entre el valor observado y el predicho:

$$e_i = y_i - \hat{y}_i$$

Propiedades

- $\sum_{i=1}^{n} e_i = 0$
- $\sum_{i=1}^{n} x_i e_i = 0$
- Deben ser pequeños y no mostrar patrones

Usos

1. **Diagnóstico del modelo:** ¿se cumplen los supuestos? ¿hay patrones no capturados?
2. **Estimación de σ^2:**

$$s^2 = \frac{\sum_{i=1}^{n} e_i^2}{n - 2}$$

3. **Detección de outliers:** puntos con residuos muy grandes

Ejemplo: publicidad y ventas

Inversión en publicidad y ventas (miles de €) durante 10 semanas:

Semana	Publicidad (X)	Ventas (Y)
1	10	45
2	15	60
3	12	50
4	18	70
5	20	75
6	8	40
7	14	55
8	16	65
9	11	48
10	13	52

Parámetros estimados

$$\hat{\beta}_1 = 3.05$$

$$\hat{\beta}_0 = 14.26$$

Ejemplo: interpretación

Modelo estimado

$$\hat{Y} = 14.26 + 3.05X$$

Interpretación

- **Intercepto** ($\hat{\beta}_0 = 14.26$): sin inversión en publicidad, las ventas base serían 14 260 €
- **Pendiente** ($\hat{\beta}_1 = 3.05$): por cada 1000 € adicionales en publicidad, las ventas aumentan en promedio 3050 €

Predicción

Si invertimos 25 000 € en publicidad:

$$\hat{Y} = 14.26 + 3.05 \times 25 \approx 90.4 \text{ miles de €}$$

Ejemplo: Python

```python
import numpy as np
from scipy import stats

# Datos
x = np.array([10, 15, 12, 18, 20, 8, 14, 16, 11, 13])
y = np.array([45, 60, 50, 70, 75, 40, 55, 65, 48, 52])

# Regresión lineal
slope, intercept, r_value, p_value, std_err = stats.linregress(x, y)

print(f"Intercepto: {intercept:.2f}")
print(f"Pendiente: {slope:.2f}")
print(f"R²: {r_value**2:.4f}")
print(f"p-value: {p_value:.4f}")

# Predicción
x_pred = 25
print(f"Predicción para x={x_pred}: {intercept + slope * x_pred:.2f}")
```

Bondad de ajuste: R^2

Coeficiente de determinación

Proporción de la variabilidad de Y explicada por X:

$$R^2 = 1 - \frac{\mathrm{SS}_{\mathrm{res}}}{\mathrm{SS}_{\mathrm{tot}}}$$

donde:

- $\mathrm{SS}_{\mathrm{res}} = \sum \left(y_i - \hat{y}_i\right)^2$ (residuos)
- $\mathrm{SS}_{\mathrm{tot}} = \sum \left(y_i - \bar{y}\right)^2$ (total)

Interpretación

- $0 \leq R^2 \leq 1$
- $R^2 = 1$: ajuste perfecto
- $R^2 = 0$: el modelo no explica nada

Relación con la correlación

En regresión simple, $R^2 = r^2$.

Ejemplo: si $R^2 = 0.85$, el 85 % de la variabilidad de las ventas se explica por la publicidad y el 15 % se debe a otros factores.