Variables aleatorias y distribuciones

Modelos predictivos en el análisis de negocios

Nebrija · MPAN

Variables aleatorias

Variable aleatoria

- Función que asigna un valor numérico a cada resultado del experimento
- Traduce fenómenos reales a valores numéricos
- Las denotamos con letras mayúsculas: X, Y, Z, ...
- Solo observamos los valores que toma la variable aleatoria: x, y, z, ...
- Pueden ser **discretas** (p. ej. conteos) o **continuas** (p. ej. medidas)

Ejemplos

- Altura de una persona → 1.75
- Satisfacción de un cliente → 1
- Suma de dos dados: $(1, 3) \to 4$
- Clientes que entran cada día en promedio → 12.27
- Minutos entre dos autobuses → 6.47

Función de probabilidad

Describe qué valores de una variable aleatoria X ocurren con más frecuencia. Se escribe en minúscula: f.

Función de masa (PMF)

- Variables aleatorias **discretas**
- Indica la probabilidad de observar un valor concreto: $f(x) = P(X = x)$

Ejemplos:

- $P(\text{Satisfacción} = 1) = 0.85$
- $P(\text{Suma de dados} = 4) = \frac{3}{36} = \frac{1}{12}$

Función de densidad (PDF)

- Variables aleatorias **continuas**
- Indica la probabilidad de observar un valor en un intervalo: $P(a < X < b) = \int_a^b f(x)\,\mathrm{d}x$

Ejemplos:

- $P(1.60 < \text{Altura} < 1.80) = 0.75$
- $P(\text{Espera} < 25) = 0.97$

Función de probabilidad: notas importantes

- La probabilidad de un valor que no está en el dominio de la variable aleatoria es 0
  - p. ej. $P(X = 0.5) = 0$ si X solo toma los valores 0 o 1
- La probabilidad de que una variable aleatoria continua tome un valor exacto es 0
- La probabilidad de una variable aleatoria continua se calcula sobre intervalos
- La probabilidad de un intervalo se obtiene integrando la función de densidad sobre dicho intervalo

> En una variable continua, $f(x)$ **no** es una probabilidad: puede ser mayor que 1. Lo que vale como probabilidad es el área bajo la curva.

Función de distribución (CDF)

- Describe la probabilidad de observar un valor menor o igual que uno dado
- También llamada **función de distribución acumulada**
- Se escribe en mayúscula: F

$$F(x) = P(X \leq x)$$

Variables discretas

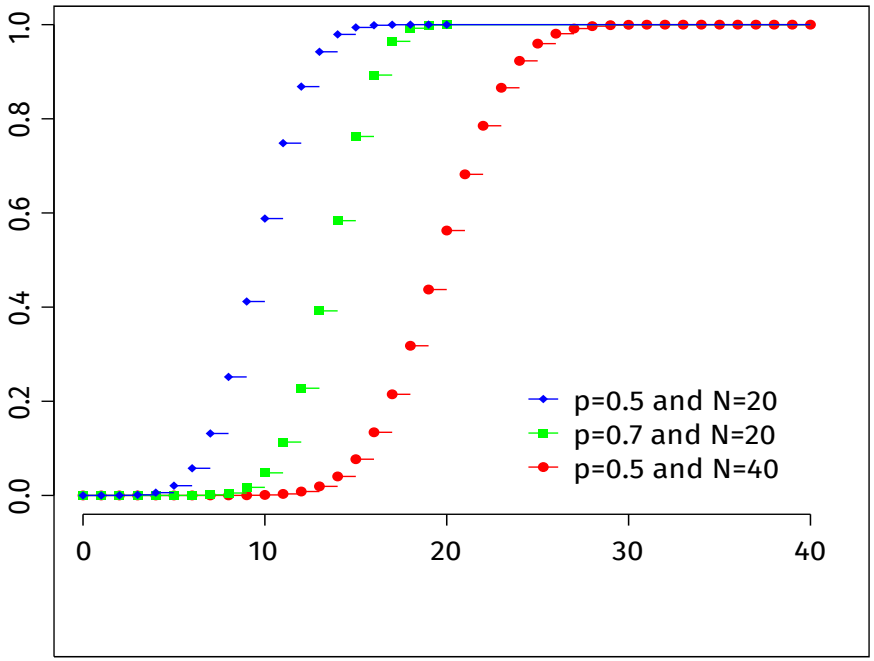
$$F(x) = \sum_{k \leq x} P(X = k)$$

Variables continuas

$$F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$$

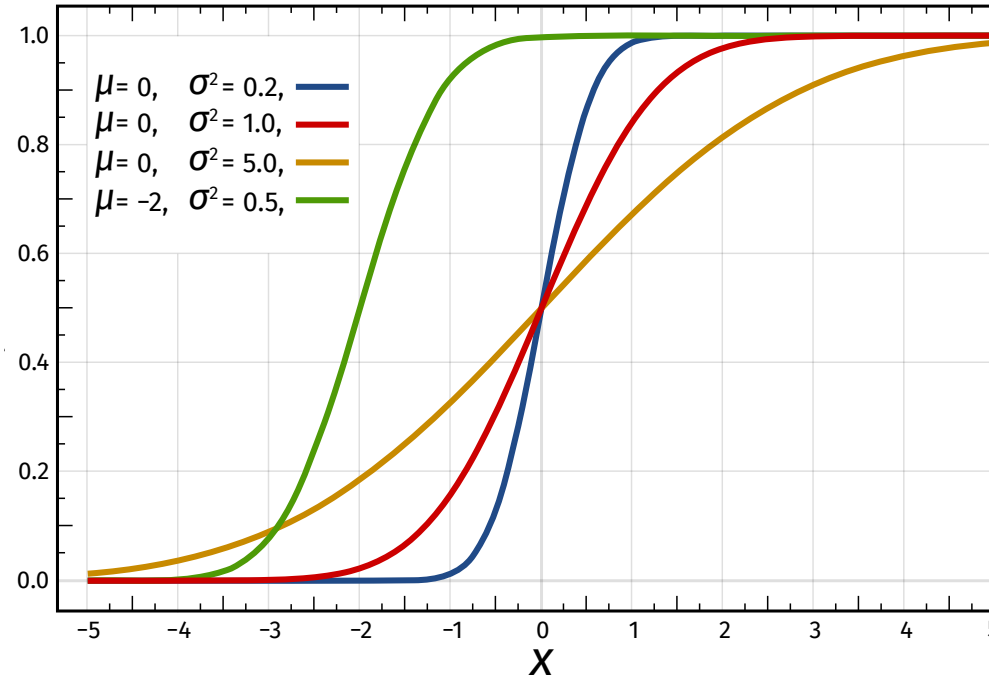
Función de distribución (CDF): ejemplos

Binomial (discreta)



Tayste, dominio público — Wikimedia Commons

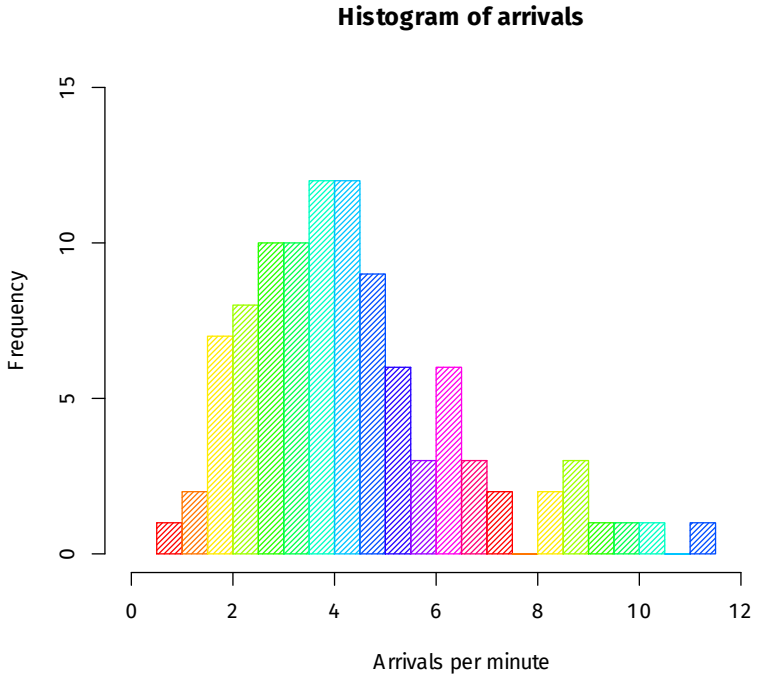
Normal (continua)



Inductiveload, dominio público — Wikimedia Commons

Distribución empírica (histograma)

- Distribución definida por una muestra observada
- Representa la frecuencia de los valores observados

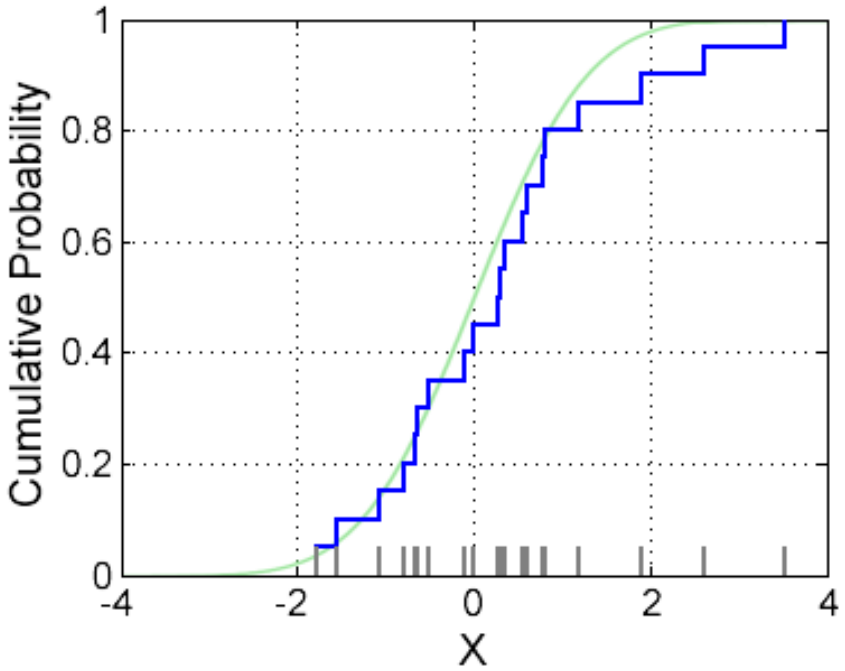


DanielPenfield, CC BY-SA 3.0 — Wikimedia Commons

Distribución empírica acumulada (ECDF)

- Función de distribución acumulada calculada a partir de los datos observados
- Útil para comparar con la distribución teórica

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n}$$



Bscan, CC0 — Wikimedia Commons

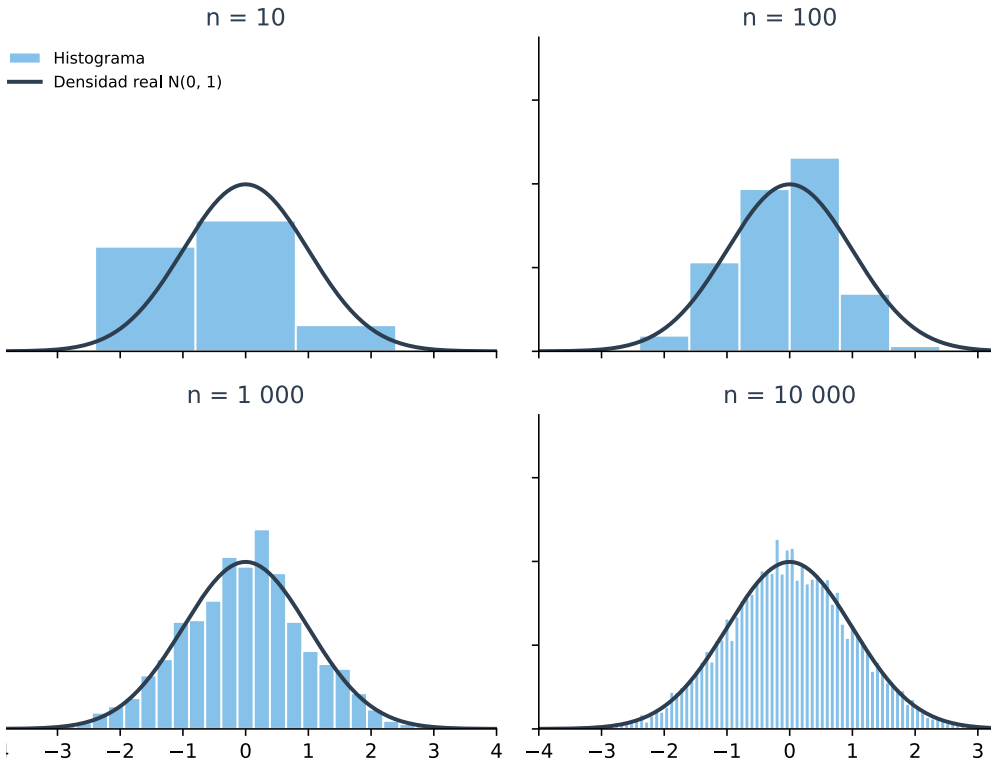
Teorema fundamental de la estadística

La distribución empírica converge a la distribución real cuando el tamaño de la muestra crece.

Si la muestra es suficientemente grande, podemos estimar los parámetros de la distribución real.

> Formalmente (Glivenko–Cantelli), la ECDF converge a la CDF: $\sup_x |\hat{F}_n(x) - F(x)| \to 0$.

Versión interactiva en la web del curso



Histogramas de muestras $N(0, 1)$ frente a la densidad real. Elaboración propia

Características de las distribuciones

X sigue una distribución con función de probabilidad f y función de distribución F:

- $F(-\infty) = 0, \quad F(\infty) = 1, \quad f(x) \geq 0$ para todo x
- Si $x < y$, entonces $F(x) \leq F(y)$ (F es no decreciente)

Si X es discreta

$$\sum_x f(x) = 1$$

Si X es continua

$$\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = 1$$

Distribuciones

Distribuciones con nombre propio

Discretas	Continuas
Uniforme (discreta)	Normal (gaussiana)
Bernoulli	Exponencial
Binomial	Beta
Poisson	Gamma
Geométrica	Uniforme (continua)
Categórica	t de Student
...	...

Uniforme discreta(a, b)

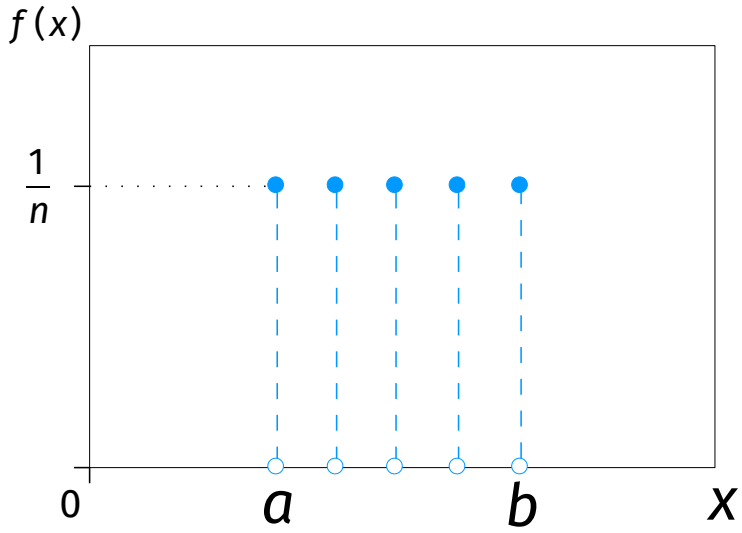
Modela $n = b - a + 1$ sucesos equiprobables entre los valores a y b (incluidos).

$$P(X = k) = \frac{1}{b - a + 1}, \quad k = a, a + 1, \ldots, b$$

Media	Varianza
$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$

Ejemplos

- Lanzamiento de dados, monedas, etc.
- Sorteos, loterías



IkamusumeFan, CC BY-SA 3.0 — Wikimedia Commons

Bernoulli(p)

Dos resultados posibles: $X = 0$ o $X = 1$

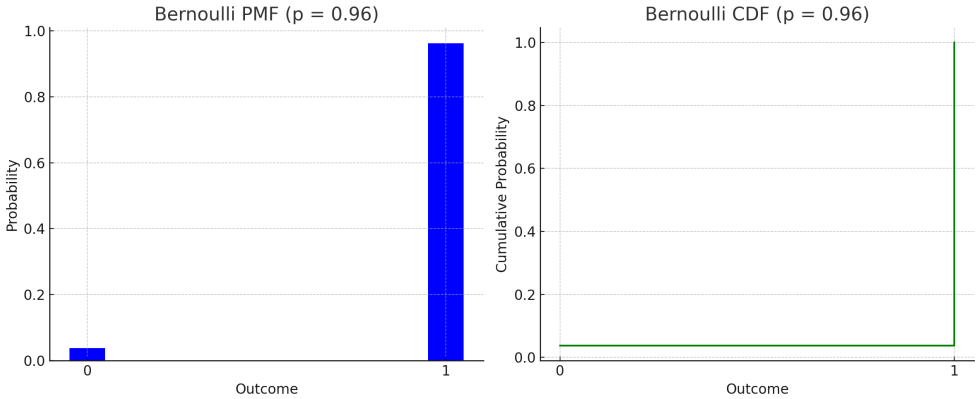
- 1 ocurre con probabilidad p
- 0 con probabilidad $q = 1 - p$

Media	Varianza
p	$p(1-p)$

Ejemplos

- Lanzamiento de una moneda
- Aprobar un examen
- Devolver un préstamo
- Cliente satisfecho o insatisfecho

$$P(X = k) = p^k(1-p)^{1-k}, \quad k \in \{0, 1\}$$



Acornellperson, CC0 — Wikimedia Commons

Binomial(n, p)

Suma de n experimentos Bernoulli(p) independientes.

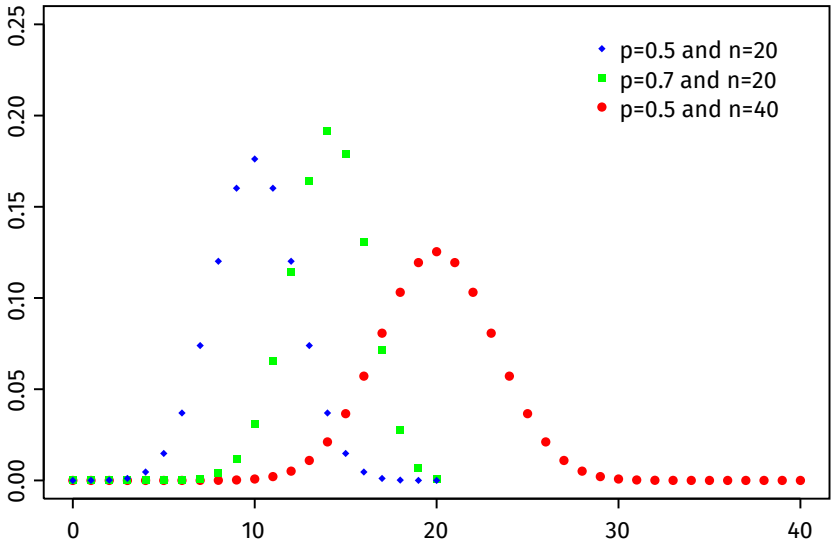
Modela la probabilidad de observar k éxitos en n intentos.

Media	Varianza
np	$np(1-p)$

Ejemplos

- Ensayos clínicos
- Conversión en marketing y ventas
- Control de calidad

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \ldots, n$$



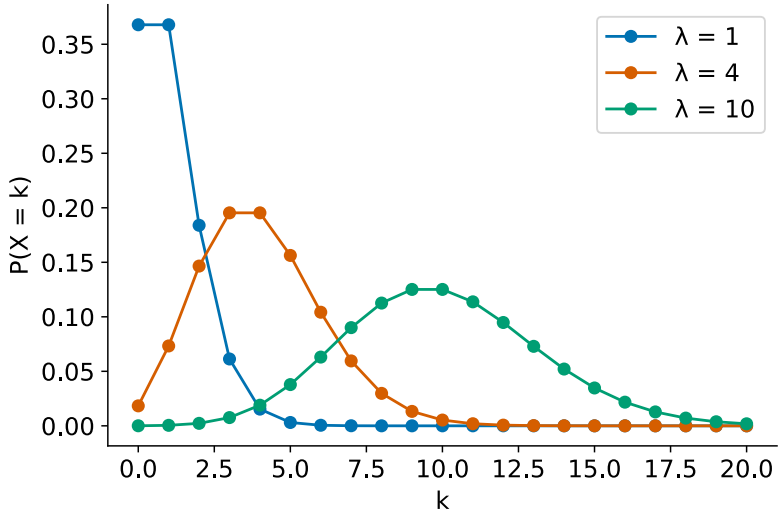
Tayste, dominio público — Wikimedia Commons

Poisson(λ)

Caso límite de la binomial cuando $n \to \infty$, $p \to 0$ y $np \to \lambda$.

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

Media	Varianza
λ	λ



Ejemplos

Número de veces que ocurre un evento en un intervalo de tiempo:

- Clientes que entran al día
- Llamadas recibidas cada día de 10 a 11
- Coches que pasan por minuto

Distribución normal o gaussiana $N(\mu, \sigma^2)$

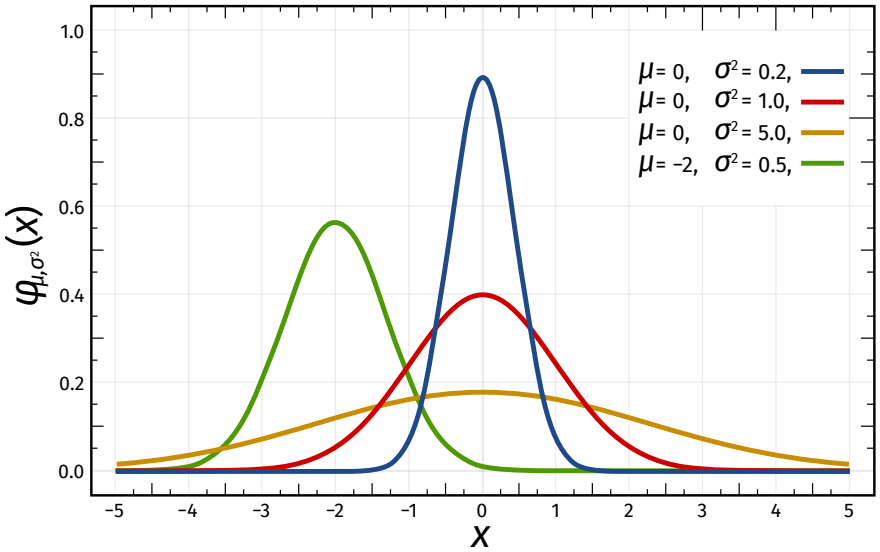
- Valores continuos en torno a un valor central μ
- La varianza σ^2 indica el grado de dispersión

Media	Varianza
μ	σ^2

Ejemplos

- Presión arterial en un grupo de pacientes
- Errores de medición en experimentos científicos
- Teorema del límite central

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Inductiveload, dominio público — Wikimedia Commons

Distribución normal estándar

- Caso particular de la normal con media $\mu = 0$ y varianza $\sigma^2 = 1$
- Se suele denotar como Z
- Si $X \sim N(\mu, \sigma^2)$, podemos transformarla en una variable aleatoria con distribución normal estándar (**tipificar**):

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

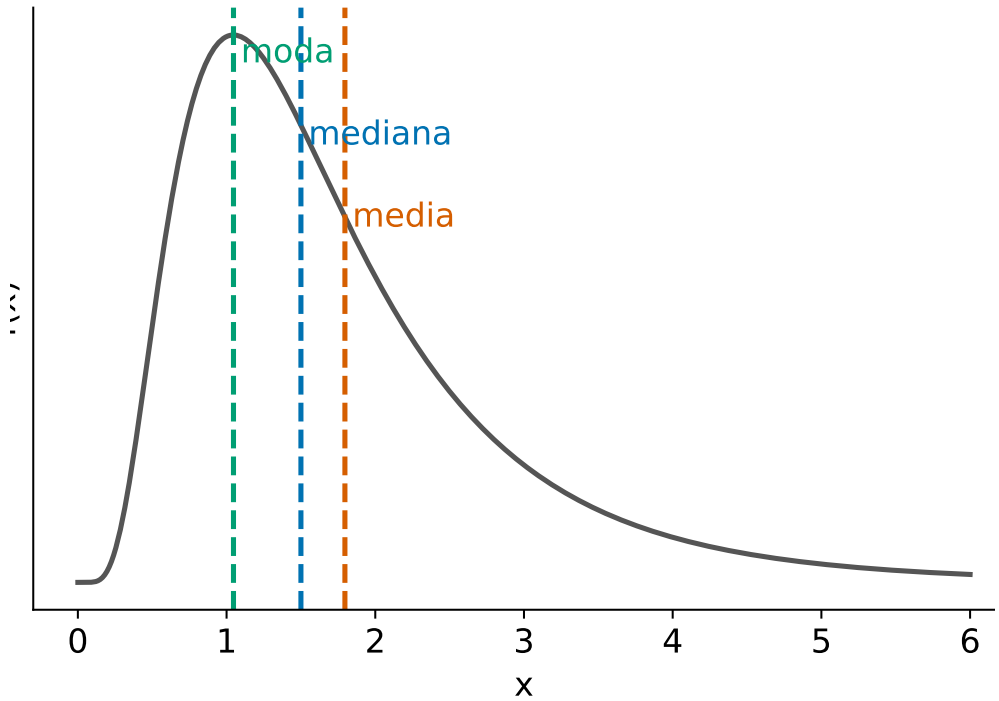
Recíprocamente, si $Z \sim N(0, 1)$, entonces:

$$\sigma Z + \mu \sim N(\mu, \sigma^2)$$

Estadísticos

Estadísticos de una distribución: centralización

- **Media (esperanza):** valor central esperado. Suma de cada valor ponderado por su probabilidad.
  - Continua: $\mu = \mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x)\,\mathrm{d}x$
  - Discreta: $\mu = \mathbb{E}[X] = \sum_x x f(x)$
- **Mediana:** valor central que divide la distribución en dos partes de igual probabilidad.
- **Moda:** valor más frecuente (máximo de f).



> En distribuciones asimétricas, media, mediana y moda no coinciden.

Estadísticos de una distribución: dispersión

- **Varianza:** medida de dispersión. Es la media del cuadrado de las desviaciones respecto a la media.

  Continua:

  $$\sigma^2 = \mathbb{V}[X] = \int_{-\infty}^{\infty} (x - \mu)^2 f(x)\,\mathrm{d}x$$

  Discreta:

  $$\sigma^2 = \mathbb{V}[X] = \sum_{x} (x - \mu)^2 f(x)$$

- **Desviación típica:** raíz cuadrada de la varianza. Indica la dispersión en las mismas unidades que la variable.

  $$\sigma = \sqrt{\sigma^2}$$

Cuantiles

- **Cuantiles:** valores que dividen la distribución en intervalos de igual probabilidad. Son la inversa de la función de distribución: $q_p = F^{-1}(p)$.
- **Mediana** = cuantil 0.5: $P(X \leq q_{0.5}) = 0.5$, $P(q_{0.5} < X) = 0.5$
- **Cuartiles** = cuantiles 0.25, 0.5 y 0.75:

$$P(X \leq q_{0.25}) = 0.25 \qquad P(q_{0.25} < X \leq q_{0.5}) = 0.25$$
$$P(q_{0.5} < X \leq q_{0.75}) = 0.25 \qquad P(q_{0.75} < X) = 0.25$$

- **Percentiles** = cuantiles 0.01, 0.02, ..., 0.99
- **Rango intercuartílico:** IQR = $q_{0.75} - q_{0.25}$. Mide la dispersión central en torno a la mediana.

Operadores sobre variables aleatorias

Linealidad de la esperanza

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

Covarianza

$$\mathrm{Cov}[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Varianza de una variable escalada

$$\mathbb{V}[aX + b] = a^2\mathbb{V}[X]$$

Varianza de la suma

$$\mathbb{V}[X \pm Y] = \mathbb{V}[X] + \mathbb{V}[Y] \pm 2\,\mathrm{Cov}[X, Y]$$

> Si X e Y son independientes, $\mathrm{Cov}[X, Y] = 0$ y $\mathbb{V}[X \pm Y] = \mathbb{V}[X] + \mathbb{V}[Y]$.